Diagnóstico de marca empleadora — RE/MAX vs. peers

Sentiment analysis (transformers) + topic modeling (BERTopic) sobre reseñas de Glassdoor

Encargo de RRHH: identificar los puntos fuertes y las áreas de mejora de RE/MAX como empleador, a partir de lo que dicen sus empleados en Glassdoor, y compararlos con los de sus competidores directos.

Peers elegidos: Keller-Williams, Colliers, Savills, Realtor-com y Century-21. Las seis empresas pertenecen al sector inmobiliario y compiten por perfiles comerciales, operativos, tecnológicos y de soporte vinculados a la intermediación y los servicios inmobiliarios. Todas superan el mínimo de 300 reseñas.

Sección	Contenido
0	Carga y preparación
1	Análisis exploratorio: rating, recomendación y evolución temporal
2	Análisis de sentimiento y control de calidad
3	Topic modeling con BERTopic
4	Interpretación temática, comparación con peers y evolución temporal
5	Empleados actuales y antiguos, antigüedad y recomendación
6	Áreas de mejora y matriz de priorización
7	Recomendaciones para Recursos Humanos
8	Limitaciones del análisis
9	Conclusión

In [1]:
```
# En Colab: transformers ya viene instalado; BERTopic no.
# !pip install -q bertopic sentence-transformers
```

0. Carga y preparación

In [2]:
```
import re
from pathlib import Path
import numpy as np
import pandas as pd
import matplotlib.pyplot as plt
import warnings
warnings.filterwarnings('ignore')



# Empresa objetivo y cinco peers del sector inmobiliario.

TARGET = 'RE/MAX'
PEERS = ['Keller-Williams', 'Colliers', 'Savills', 'Realtor-com', 'Century-21']
FIRMS = [TARGET] + PEERS


# Tope de reseñas por empresa: acota el tiempo de cómputo y evita que el peer
# más grande domine el modelo de topics conjunto

MAX_POR_EMPRESA = 1000 # Límite máximo de reseñas por empresa. con 1000 por empresa puede ser suficiente, los modelos preentrenados de sentimiento
pueden tardar bastante en procesar
SEED = 42

# Carpeta de visualizaciones compatible con ejecución local y Colab
IMAGES_DIR = next(
    (ruta for ruta in [Path('../imagenes'), Path('imagenes')] if ruta.exists()),
    Path('imagenes'),
)
IMAGES_DIR.mkdir(parents=True, exist_ok=True)

# Rutas compatibles con ejecución local desde notebooks/, desde la raíz del proyecto
# y con un fichero subido directamente a Google Colab.
DATA_CANDIDATES = [
    Path('../data/raw/glassdoor_reviews_hr.parquet'),
    Path('data/raw/glassdoor_reviews_hr.parquet'),
    Path('glassdoor_reviews_hr.parquet'),
]
DATA_PATH = next((path for path in DATA_CANDIDATES if path.exists()), None)
if DATA_PATH is None:
    raise FileNotFoundError('No se encontró glassdoor_reviews_hr.parquet')
```

```
raw = pd.read_parquet(DATA_PATH, filters=[('firm', 'in', FIRMS)])
print('Reseñas disponibles por empresa:')
print(raw['firm'].value_counts())

df = pd.concat([g.sample(n=min(MAX_POR_EMPRESA, len(g)), random_state=SEED)
                for _, g in raw.groupby('firm')], ignore_index=True)
print(f'\nMuestra de trabajo: {len(df):,} reseñas')
```

```
Reseñas disponibles por empresa:
firm
Keller-Williams    3071
Colliers           1362
RE/MAX             1133
Savills             960
Realtor-com         601
Century-21          445
Name: count, dtype: int64

Muestra de trabajo: 5,006 reseñas
```

La columna `current` mezcla situación y antigüedad (`"Former Employee, more than 3 years"`). La separo en dos variables. También traduzco `recommend` (v = sí, o = sin opinión, x = no) y limpio saltos de línea del texto.

In [3]:

```
def situacion(s):
    s = str(s).lower()
    if s.startswith('current'):
        return 'Actual'
    if s.startswith('former'):
        return 'Antiguo'
    return 'Desconocido'

def antiguedad(s):
    m = re.search(r'(less|more) than (\d+) year', str(s))
    return f'{m.group(1)} than {m.group(2)}y' if m else 'n/d'

df['situacion'] = df['current'].map(situacion)
df['antiguedad'] = df['current'].map(antiguedad)
df['recomienda'] = df['recommend'].map({'v': 'Sí', 'o': 'Neutral', 'x': 'No'})
df['date_review'] = pd.to_datetime(df['date_review'])
df['anio'] = df['date_review'].dt.year

for col in ['pros', 'cons']:
    df[col] = df[col].astype(str).str.replace(r'\s+', ' ', regex=True).str.strip()

print(df['situacion'].value_counts())
df[['firm', 'date_review', 'situacion', 'antiguedad', 'overall_rating', 'recomienda', 'pros', 'cons']].head()
```

```
situacion
Actual     2870
Antiguo    2136
Name: count, dtype: int64
```

Out[3]:

	firm	date_review	situacion	antiguedad	overall_rating	recomienda	pros	cons
0	Century-21	2022-03-09	Antiguo	n/d	3.0	Neutral	Flexibility, time, leadership, continuous trai...	Salary model does not apply to agents
1	Century-21	2022-09-06	Actual	less than 1y	3.0	Neutral	Easy hours, available shifts, computer work	Pay is horrible, unorganized and no communication
2	Century-21	2020-09-05	Antiguo	more than 1y	4.0	Sí	Great coworkers, keeps you busy, good management	A little crazy during holidays
3	Century-21	2023-01-19	Actual	n/d	5.0	Neutral	good support for field agents	nothing to report as needing repair.
4	Century-21	2019-10-30	Antiguo	less than 1y	3.0	Sí	My specific office is very nice. We have a sal...	At the end of the day, you have to make it hap...

---

1. EDA. Análisis exploratorio

En esta sección se compara el volumen de reseñas, la valoración media, el porcentaje de recomendación y la composición entre empleados actuales y antiguos. El objetivo es detectar diferencias iniciales entre RE/MAX y sus peers antes de analizar el texto.

In [4]:

```python
# Resumen de indicadores por empresa
resumen_empresa = (
    df.groupby('firm', observed=True)
      .agg(
          n_reseñas=('firm', 'size'),
          rating_medio=('overall_rating', 'mean'),
          pct_recomienda=('recomienda', lambda s: s.eq('Sí').mean() * 100),
          pct_actuales=('situacion', lambda s: s.eq('Actual').mean() * 100),
          pct_antiguos=('situacion', lambda s: s.eq('Antiguo').mean() * 100),
      )
      .reindex(FIRMS)
)

resumen_empresa = resumen_empresa.round({
    'rating_medio': 2,
    'pct_recomienda': 1,
    'pct_actuales': 1,
    'pct_antiguos': 1,
```

```
})

resumen_empresa
```

Out[4]:

firm	n_reseñas	rating_medio	pct_recomienda	pct_actuales	pct_antiguos
RE/MAX	1000	4.10	42.2	56.8	43.2
Keller-Williams	1000	4.13	47.9	60.6	39.4
Colliers	1000	3.59	40.0	52.9	47.1
Savills	960	3.75	44.1	59.2	40.8
Realtor-com	601	3.39	39.3	56.2	43.8
Century-21	445	4.06	44.5	58.7	41.3

In [5]:

```
# Comparación de RE/MAX con la media simple de sus peers
metricas_comparacion = [
    'rating_medio',
    'pct_recomienda',
    'pct_actuales',
    'pct_antiguos',
]

comparacion_remax = pd.DataFrame({
    'RE/MAX': resumen_empresa.loc[TARGET, metricas_comparacion],
    'Media peers': resumen_empresa.loc[PEERS, metricas_comparacion].mean(),
})

comparacion_remax['Gap RE/MAX vs. peers'] = (
    comparacion_remax['RE/MAX'] - comparacion_remax['Media peers']
)

comparacion_remax.round(2)
```

Out[5]:

	RE/MAX	Media peers	Gap RE/MAX vs. peers
rating_medio	4.1	3.78	0.32
pct_recomienda	42.2	43.16	-0.96
pct_actuales	56.8	57.52	-0.72
pct_antiguos	43.2	42.48	0.72

Primera lectura del EDA

RE/MAX presenta una valoración media de 4,10 sobre 5, aproximadamente 0,32 puntos por encima de la media simple de sus peers. Solo Keller-Williams obtiene una valoración ligeramente superior.

Esta fortaleza no se refleja completamente en la recomendación: el 42,2% de las reseñas de RE/MAX recomienda la empresa, aproximadamente un punto porcentual menos que la media de los peers. Esta diferencia aconseja investigar si existen aspectos concretos de la experiencia laboral que reducen la disposición a recomendar RE/MAX a pesar de su elevada valoración general.

La proporción de empleados actuales y antiguos es parecida a la del conjunto de peers, por lo que no parece existir una diferencia de composición suficientemente grande como para explicar por sí sola los resultados.

Rating de empleados actuales y antiguos

Comparación de ambos grupos

In [6]:
```
# Rating medio según la situación laboral
rating_situacion = (
    df.pivot_table(
        index='firm',
        columns='situacion',
        values='overall_rating',
        aggfunc='mean',
    )
    .reindex(FIRMS)
    .reindex(columns=['Actual', 'Antiguo'])
)

rating_situacion['brecha_actual_antiguo'] = (
    rating_situacion['Actual'] - rating_situacion['Antiguo']
)

rating_situacion.round(2)
```

Out[6]:

situacion firm	Actual	Antiguo	brecha_actual_antiguo
RE/MAX	4.36	3.75	0.60
Keller-Williams	4.41	3.70	0.71
Colliers	3.93	3.20	0.73
Savills	4.06	3.30	0.76
Realtor-com	3.66	3.04	0.61
Century-21	4.34	3.65	0.69

In [7]:

```
import seaborn as sns

sns.set_theme(style='whitegrid')

datos_rating_situacion = (
    df.groupby(['firm', 'situacion'], observed=True)
      .agg(
          rating_medio=('overall_rating', 'mean'),
          n_reseñas=('overall_rating', 'size'),
      )
      .reset_index()
)

fig, ax = plt.subplots(figsize=(11, 5))

sns.barplot(
    data=datos_rating_situacion,
    x='firm',
    y='rating_medio',
    hue='situacion',
    order=FIRMS,
    hue_order=['Actual', 'Antiguo'],
    palette={'Actual': '#2A9D8F', 'Antiguo': '#E76F51'},
    ax=ax,
)

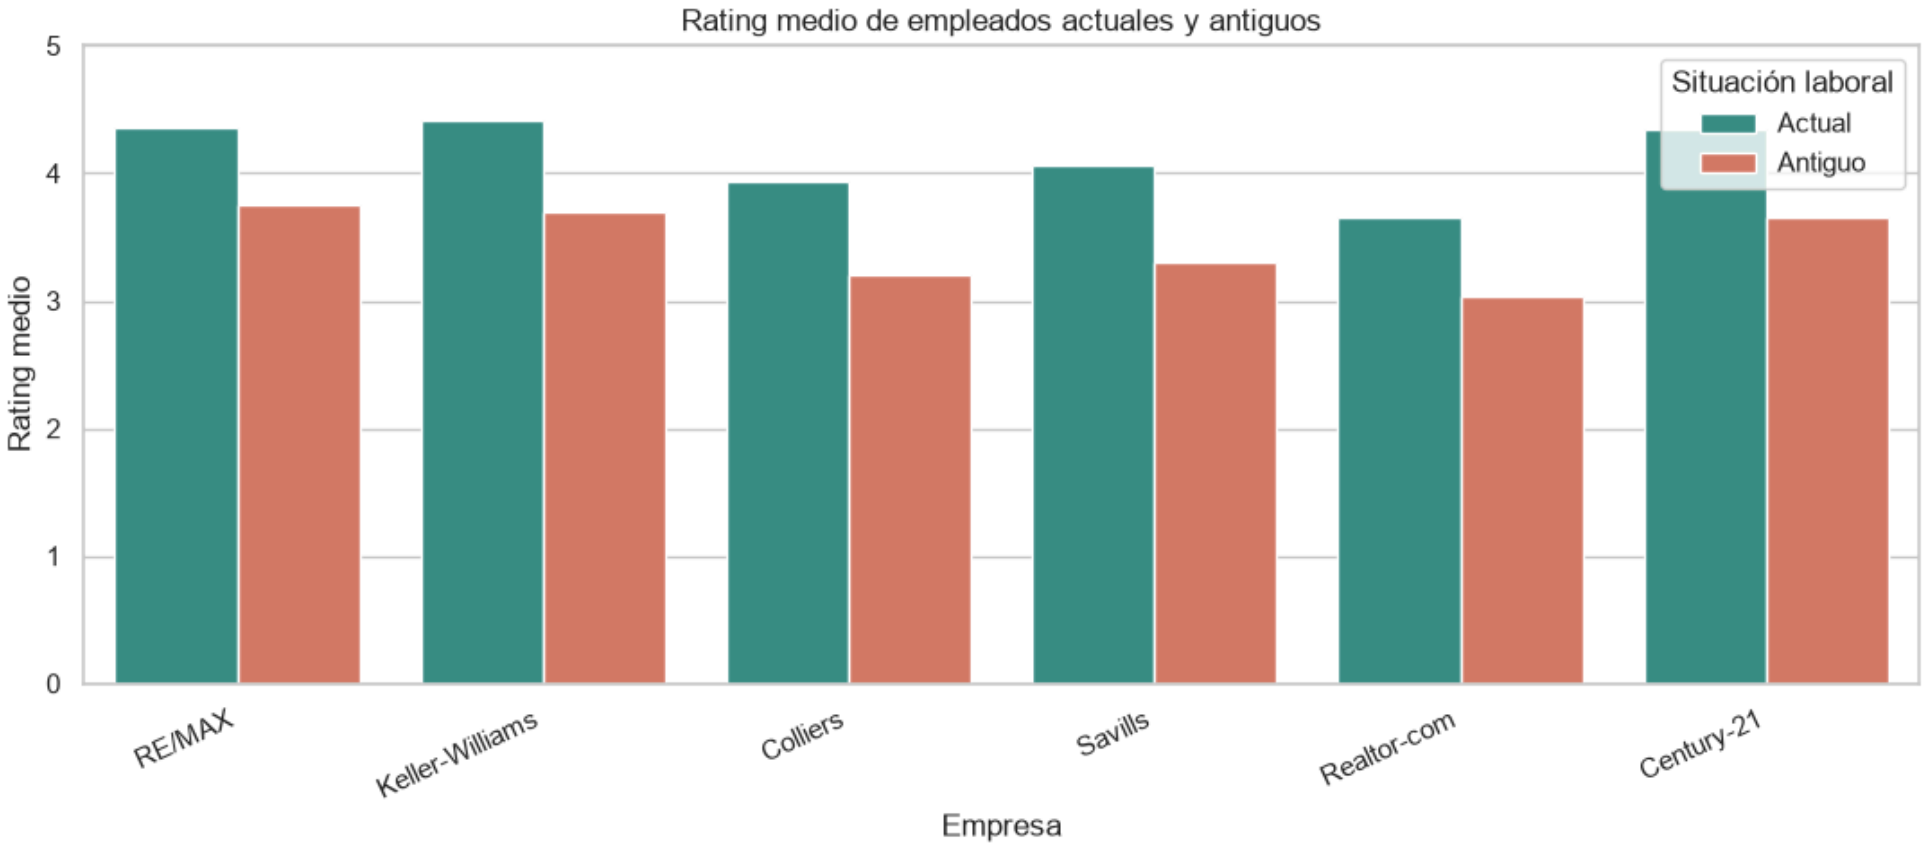
ax.set(
    title='Rating medio de empleados actuales y antiguos',
    xlabel='Empresa',
    ylabel='Rating medio',
    ylim=(0, 5),
)

plt.xticks(rotation=25, ha='right')
```

```
plt.legend(title='Situación laboral')
plt.tight_layout()

fig.savefig(
    IMAGES_DIR / 'rating_medio_de_empleados_actuales_y_antiguos.png',
    dpi=160,
    bbox_inches='tight',
)

plt.show()
```



Empleados actuales frente a antiguos

Los empleados actuales otorgan valoraciones superiores a los antiguos en todas las empresas, lo que confirma el sesgo de selección advertido en el enunciado.

RE/MAX obtiene un rating de 4,36 entre sus empleados actuales y de 3,75 entre los antiguos. La diferencia es de 0,60 puntos, aproximadamente 0,10 puntos menor que la brecha media de sus peers. Además, RE/MAX presenta la valoración más alta entre los antiguos empleados de las seis compañías analizadas.

Este resultado constituye una señal positiva: aunque la experiencia de quienes han abandonado la empresa es menos favorable, el deterioro es menor que en la competencia. No obstante, la comparación relevante será identificar qué temas aparecen en los comentarios negativos de los antiguos empleados, ya que pueden representar motivos potenciales de salida.

Evolución temporal del rating

In [8]:
```
# Evolución anual del rating por empresa
evolucion_rating = (
    df.groupby(['firm', 'anio'], observed=True)
      .agg(
          rating_medio=('overall_rating', 'mean'),
          n_reseñas=('overall_rating', 'size'),
      )
      .reset_index()
)

tabla_evolucion = (
    evolucion_rating
    .pivot(index='anio', columns='firm', values='rating_medio')
    .reindex(columns=FIRMS)
    .round(2)
)

tabla_evolucion
```

Out[8]:

firm anio	RE/MAX	Keller-Williams	Colliers	Savills	Realtor-com	Century-21
2018	3.87	4.07	3.29	3.55	3.46	4.00
2019	4.03	4.01	3.45	3.38	2.77	3.98
2020	4.05	4.17	3.53	3.79	3.21	4.03
2021	4.06	4.17	3.63	3.74	3.51	4.07
2022	4.21	4.13	3.60	3.91	3.50	4.11
2023	4.05	4.13	3.70	3.61	3.72	4.02

RE/MAX frente a los peers

In [9]:
```python
# Comparación temporal de RE/MAX con la media de los peers
media_peers_anual = (
    evolucion_rating[evolucion_rating['firm'].isin(PEERS)]
    .groupby('anio', observed=True)['rating_medio']
    .mean()
    .rename('Media peers')
)

evolucion_remax = (
    evolucion_rating[evolucion_rating['firm'].eq(TARGET)]
    .set_index('anio')['rating_medio']
    .rename('RE/MAX')
)

comparacion_temporal = pd.concat(
    [evolucion_remax, media_peers_anual],
    axis=1,
)

comparacion_temporal['Gap RE/MAX vs. peers'] = (
    comparacion_temporal['RE/MAX'] -
    comparacion_temporal['Media peers']
)

comparacion_temporal.round(2)
```

Out[9]:

anio	RE/MAX	Media peers	Gap RE/MAX vs. peers
2018	3.87	3.67	0.19
2019	4.03	3.52	0.51
2020	4.05	3.75	0.31
2021	4.06	3.82	0.23
2022	4.21	3.85	0.36
2023	4.05	3.84	0.21

In [10]:
```python
# Evolución anual del rating: RE/MAX frente a sus peers

fig, ax = plt.subplots(figsize=(10, 5))
```

```
ax.plot(
    comparacion_temporal.index,
    comparacion_temporal['RE/MAX'],
    marker='o',
    linewidth=2.8,
    color='#D62828',
    label='RE/MAX',
)

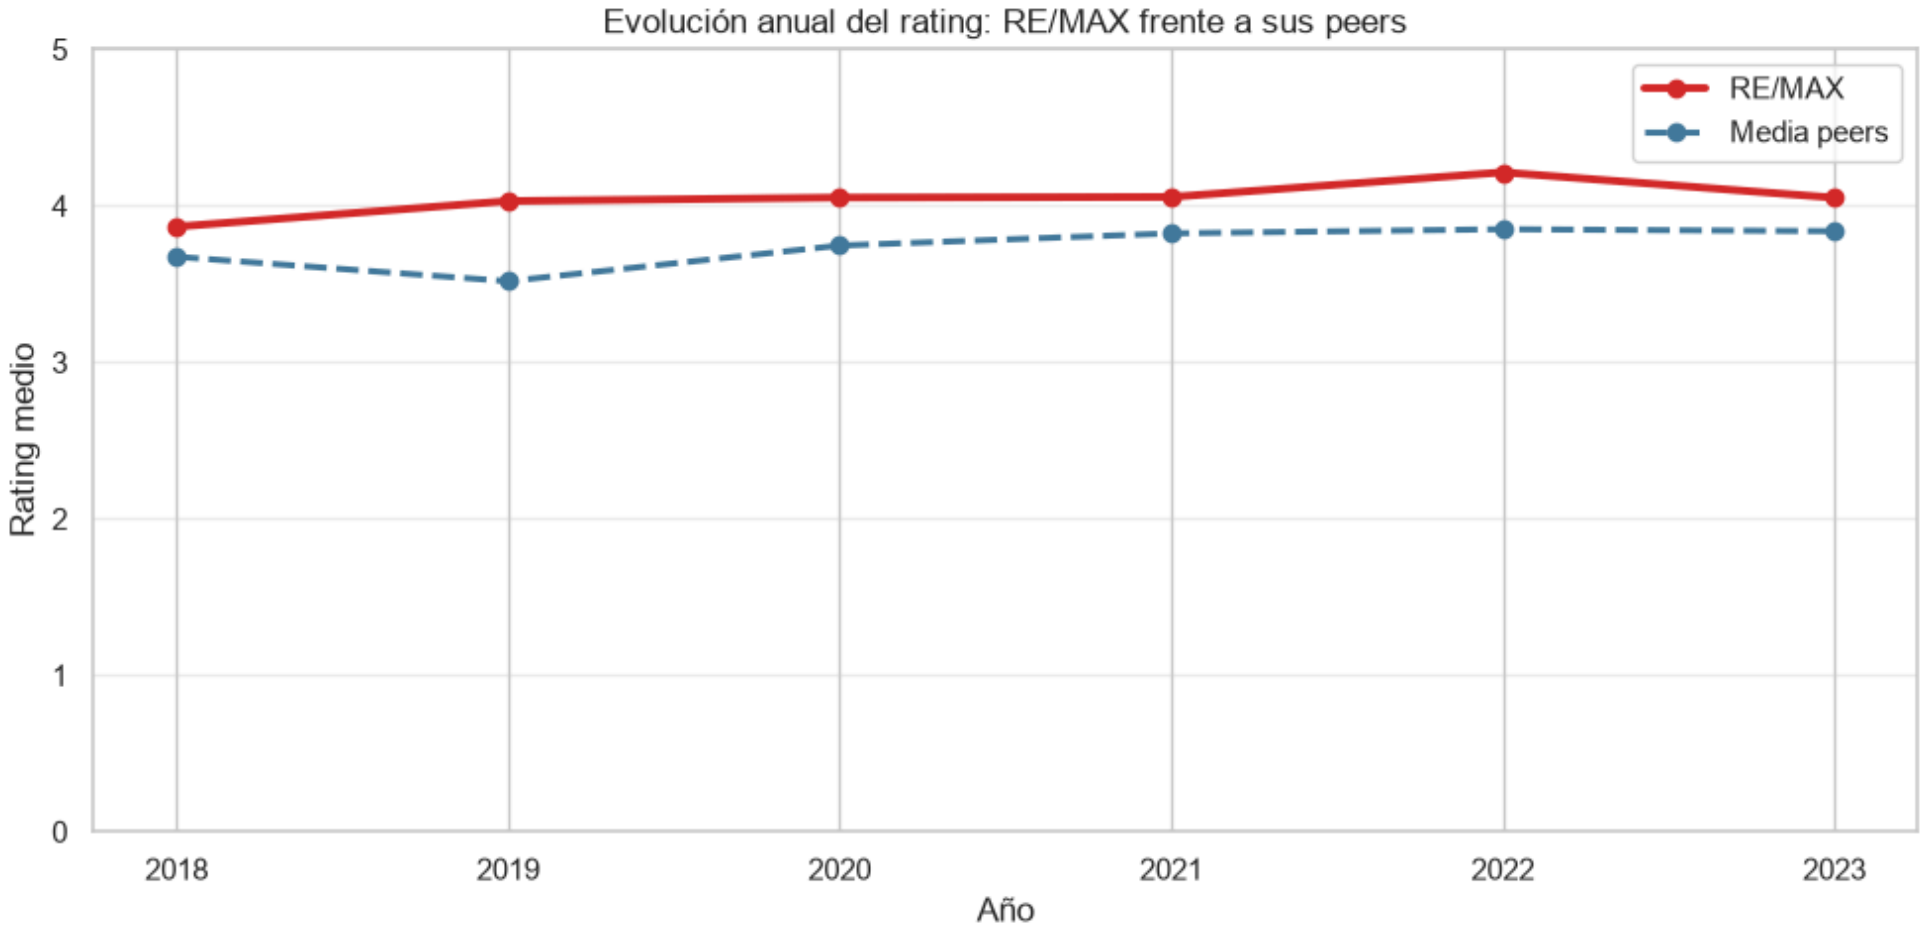
ax.plot(
    comparacion_temporal.index,
    comparacion_temporal['Media peers'],
    marker='o',
    linewidth=2.2,
    color='#457B9D',
    linestyle='--',
    label='Media peers',
)

ax.set(
    title='Evolución anual del rating: RE/MAX frente a sus peers',
    xlabel='Año',
    ylabel='Rating medio',
    ylim=(0, 5),
)

ax.legend()
ax.grid(axis='y', alpha=0.3)
plt.tight_layout()

fig.savefig(
    IMAGES_DIR / 'evolucion_rating_remax_vs_peers.png',
    dpi=160,
    bbox_inches='tight',
)

plt.show()
```



Lectura de la evolución temporal

RE/MAX mantiene un rating superior a la media simple de sus peers durante todos los años analizados. La ventaja anual oscila entre aproximadamente 0,19 y 0,51 puntos, por lo que la fortaleza relativa no depende de un único periodo.

El rating de RE/MAX se mantiene estable alrededor de 4 puntos entre 2019 y 2021 y alcanza su máximo en 2022, con 4,21. En 2023 desciende hasta 4,05, pero continúa por encima de la media de los peers.

Los datos de 2018 y 2023 cubren años incompletos, por lo que sus variaciones deben interpretarse con cautela. Desde la perspectiva de RRHH, convendría investigar qué cambios o prácticas coinciden con la mejora observada en 2022 y valorar si pueden mantenerse o extenderse.

2. Sentimiento en pros y cons

Se utiliza `distilbert-base-uncased-finetuned-sst-2-english`, un modelo transformer preentrenado para clasificación binaria de sentimiento en inglés.

Este análisis funciona como control de calidad: dado que `pros` recoge aspectos positivos y `cons` aspectos negativos, esperamos que la mayoría de los primeros se clasifiquen como positivos y la mayoría de los segundos como negativos.

El modelo no dispone de una categoría neutral. Además, los textos que superen el límite de 512 tokens se truncarán para evitar errores. Los casos discordantes se revisarán manualmente, ya que pueden contener ironía, respuestas genéricas, ausencia de contenido o comentarios que mezclan aspectos positivos y negativos.

In [11]:
```python
# Carga del modelo
import torch
from transformers import pipeline
from tqdm.auto import tqdm

MODELO_SENTIMIENTO = 'distilbert-base-uncased-finetuned-sst-2-english'

if torch.backends.mps.is_available():
    DISPOSITIVO = 'mps'
elif torch.cuda.is_available():
    DISPOSITIVO = 0
else:
    DISPOSITIVO = -1

print(f'Dispositivo utilizado: {DISPOSITIVO}')

clasificador_sentimiento = pipeline(
    task='sentiment-analysis',
    model=MODELO_SENTIMIENTO,
    device=DISPOSITIVO,
)
```

```
Dispositivo utilizado: mps
```

In [12]:
```python
# Inferencia sobre pros y cons
def inferir_sentimiento(textos, batch_size=32):
    """Clasifica textos por lotes y devuelve etiqueta y confianza."""
```

```
    textos = textos.fillna('').astype(str).tolist()

    etiquetas = []
    confianzas = []

    for inicio in tqdm(
        range(0, len(textos), batch_size),
        desc='Clasificando sentimiento',
    ):
        lote = textos[inicio:inicio + batch_size]

        resultados = clasificador_sentimiento(
            lote,
            truncation=True,
            max_length=512,
            batch_size=batch_size,
        )

        etiquetas.extend(resultado['label'] for resultado in resultados)
        confianzas.extend(resultado['score'] for resultado in resultados)

    return etiquetas, confianzas


df['pros_sentimiento'], df['pros_confianza'] = inferir_sentimiento(df['pros'])
df['cons_sentimiento'], df['cons_confianza'] = inferir_sentimiento(df['cons'])

df[
    [
        'firm',
        'pros',
        'pros_sentimiento',
        'pros_confianza',
        'cons',
        'cons_sentimiento',
        'cons_confianza',
    ]
].head()
```

Out[12]:

	firm	pros	pros_sentimiento	pros_confianza	cons	cons_sentimiento	cons_confianza
0	Century-21	Flexibility, time, leadership, continuous trai...	POSITIVE	0.999455	Salary model does not apply to agents	NEGATIVE	0.999227
1	Century-21	Easy hours, available shifts, computer work	POSITIVE	0.716582	Pay is horrible, unorganized and no communication	NEGATIVE	0.999764
2	Century-21	Great coworkers, keeps you busy, good management	POSITIVE	0.999874	A little crazy during holidays	NEGATIVE	0.733457
3	Century-21	good support for field agents	POSITIVE	0.999840	nothing to report as needing repair.	NEGATIVE	0.995622
4	Century-21	My specific office is very nice. We have a sal...	POSITIVE	0.999823	At the end of the day, you have to make it hap...	NEGATIVE	0.993075

Resultado por empresa

In [13]:

```
# Resultado por empresa
control_sentimiento = (
    df.groupby('firm', observed=True)
      .agg(
          n_reseñas=('firm', 'size'),
          pct_pros_positivos=(
              'pros_sentimiento',
              lambda s: s.eq('POSITIVE').mean() * 100,
          ),
          pct_cons_negativos=(
              'cons_sentimiento',
              lambda s: s.eq('NEGATIVE').mean() * 100,
          ),
          confianza_media_pros=('pros_confianza', 'mean'),
          confianza_media_cons=('cons_confianza', 'mean'),
      )
      .reindex(FIRMS)
)

control_sentimiento = control_sentimiento.round({
    'pct_pros_positivos': 1,
    'pct_cons_negativos': 1,
    'confianza_media_pros': 3,
    'confianza_media_cons': 3,
})

control_sentimiento
```

Out[13]:

firm	n_reseñas	pct_pros_positivos	pct_cons_negativos	confianza_media_pros	confianza_media_cons
RE/MAX	1000	92.6	77.7	0.990	0.970
Keller-Williams	1000	94.3	76.0	0.990	0.972
Colliers	1000	92.3	81.6	0.991	0.975
Savills	960	93.0	81.2	0.991	0.979
Realtor-com	601	88.2	80.4	0.987	0.972
Century-21	445	93.0	74.8	0.990	0.974

Control de calidad del modelo de sentimiento

El modelo clasifica como positivos el 92,6% de los pros de RE/MAX, un resultado prácticamente igual a la media de sus peers. Esto confirma que el modelo identifica correctamente la orientación positiva de la mayoría de estos textos.

El porcentaje de cons clasificados como negativos es menor: 77,7% en RE/MAX y aproximadamente 78,8% en los peers. Este resultado no implica necesariamente que el modelo falle en uno de cada cinco casos. Algunos comentarios incluidos en `cons` pueden indicar que no existen aspectos negativos, utilizar expresiones positivas, contener ironía o mezclar ventajas e inconvenientes.

Las probabilidades medias son elevadas tanto en pros como en cons. Por ello, los casos discordantes deben revisarse atendiendo al contenido y no únicamente a la confianza del modelo.

In [14]:
```
# Visualización del control de calidad

control_plot = (
    control_sentimiento[
        ['pct_pros_positivos', 'pct_cons_negativos']
    ]
    .rename(columns={
        'pct_pros_positivos': 'Pros clasificados como positivos',
        'pct_cons_negativos': 'Cons clasificados como negativos',
    })
    .reset_index()
    .melt(
        id_vars='firm',
        var_name='Control',
        value_name='Porcentaje',
    )
)
```

```
fig, ax = plt.subplots(figsize=(11, 5))

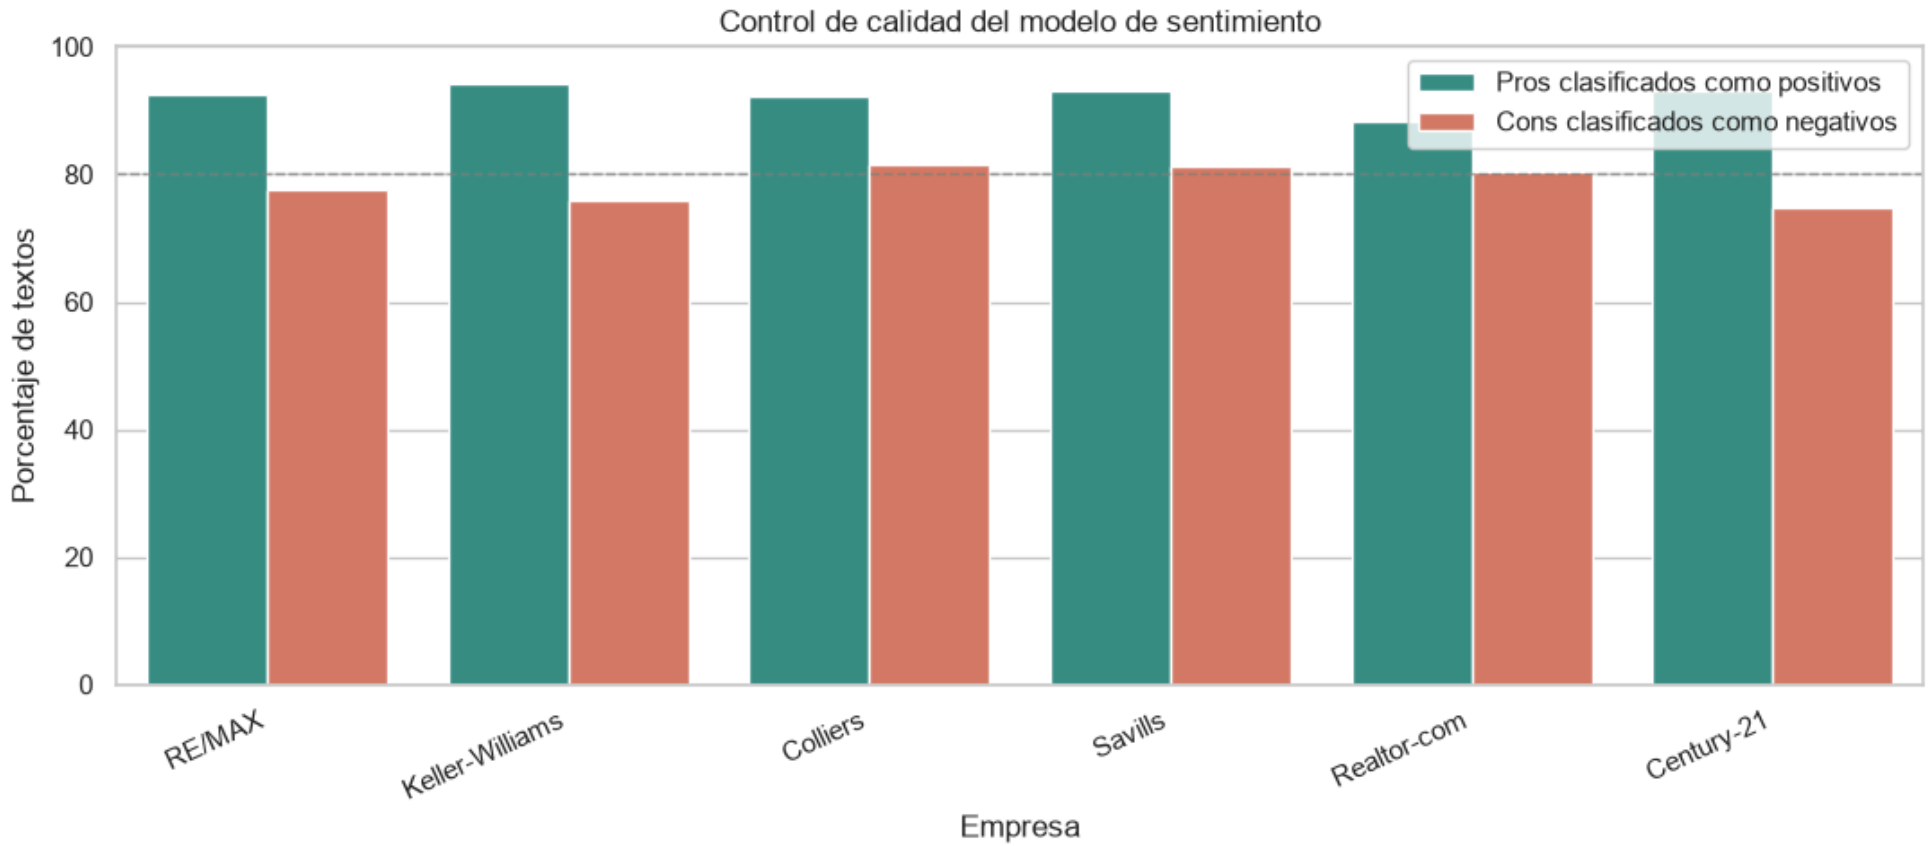
sns.barplot(
    data=control_plot,
    x='firm',
    y='Porcentaje',
    hue='Control',
    order=FIRMS,
    palette=['#2A9D8F', '#E76F51'],
    ax=ax,
)

ax.set(
    title='Control de calidad del modelo de sentimiento',
    xlabel='Empresa',
    ylabel='Porcentaje de textos',
    ylim=(0, 100),
)

ax.axhline(80, color='gray', linestyle='--', linewidth=1, alpha=0.7)
ax.legend(title='')
plt.xticks(rotation=25, ha='right')
plt.tight_layout()

fig.savefig(
    IMAGES_DIR / 'control_calidad_sentimiento.png',
    dpi=160,
    bbox_inches='tight',
)

plt.show()
```



In [15]:
```python
# Revisión manual de discordancias entre el campo original (pros o cons)
# y el sentimiento inferido. El rating y la recomendación se muestran
# únicamente como contexto para interpretar cada caso.



def seleccionar_discordantes(
    datos,
    columna_etiqueta,
    etiqueta_discordante,
    columna_texto,
    n_target=8,
    n_por_peer=1,
):
    """Selecciona casos discordantes de RE/MAX y de cada peer."""
    casos = datos[
        datos[columna_etiqueta].eq(etiqueta_discordante)
```

```
    ].copy()

    muestra_target = casos[casos['firm'].eq(TARGET)].sample(
        n=min(n_target, casos['firm'].eq(TARGET).sum()),
        random_state=SEED,
    )

    muestras_peers = []
    for peer in PEERS:
        casos_peer = casos[casos['firm'].eq(peer)]

        if not casos_peer.empty:
            muestras_peers.append(
                casos_peer.sample(
                    n=min(n_por_peer, len(casos_peer)),
                    random_state=SEED,
                )
            )

    muestra = pd.concat(
        [muestra_target, *muestras_peers],
        ignore_index=True,
    )

    return muestra[
        [
            'firm',
            'date_review',
            'overall_rating',
            'recomienda',
            columna_texto,
            columna_etiqueta,
            columna_etiqueta.replace('sentimiento', 'confianza'),
        ]
    ]
```

In [16]:

```
# Pros clasificados como negativos

muestra_pros_negativos = seleccionar_discordantes(
    datos=df,
    columna_etiqueta='pros_sentimiento',
    etiqueta_discordante='NEGATIVE',
    columna_texto='pros',
)

with pd.option_context('display.max_colwidth', 300):
    display(muestra_pros_negativos)
```

	firm	date_review	overall_rating	recomienda	pros	pros_sentimiento	pros_confianza
0	RE/MAX	2018-12-04	1.0	No	none, it would be difficult to find anything pros	NEGATIVE	0.998985
1	RE/MAX	2020-04-21	3.0	No	Hours Were good, but it was part time	NEGATIVE	0.920868
2	RE/MAX	2019-01-31	5.0	Sí	You got a lot of leads and not many agents to compete with.	NEGATIVE	0.967484
3	RE/MAX	2019-01-14	1.0	Neutral	No pros thay one can mention	NEGATIVE	0.955975
4	RE/MAX	2020-09-01	4.0	Sí	Working on your own schedule.	NEGATIVE	0.977128
5	RE/MAX	2023-02-14	3.0	Neutral	Not flexible in work hours No over time offered	NEGATIVE	0.999255
6	RE/MAX	2021-08-26	4.0	Neutral	Make your own schedule days	NEGATIVE	0.663606
7	RE/MAX	2020-11-06	3.0	Sí	Good but not perfect, should be better	NEGATIVE	0.975849
8	Keller-Williams	2021-04-27	3.0	Neutral	Pay scale for realtor commission	NEGATIVE	0.801419
9	Colliers	2020-07-24	1.0	No	Female upper management - very dismissive of sexual and physical harassment.	NEGATIVE	0.999578
10	Savills	2023-05-31	2.0	No	None that I can think of	NEGATIVE	0.996586
11	Realtor-com	2020-05-09	2.0	No	i don't see any pros	NEGATIVE	0.998981
12	Century-21	2023-01-10	1.0	No	Not many pros I can think of, Antique atmosphere?	NEGATIVE	0.993974

In [17]:
```
# Cons clasificados como positivos

muestra_cons_positivos = seleccionar_discordantes(
    datos=df,
    columna_etiqueta='cons_sentimiento',
    etiqueta_discordante='POSITIVE',
    columna_texto='cons',
)

with pd.option_context('display.max_colwidth', 300):
    display(muestra_cons_positivos)
```

	firm	date_review	overall_rating	recomienda	cons	cons_sentimiento	cons_confianza
0	RE/MAX	2020-11-13	5.0	Sí	No Cons that i can think of	POSITIVE	0.996827
1	RE/MAX	2022-01-07	4.0	Neutral	Doing business there is quite expensive.	POSITIVE	0.955080
2	RE/MAX	2019-08-16	4.0	Neutral	Very high fees Splits for new agents are in their favor	POSITIVE	0.695837
3	RE/MAX	2021-08-30	5.0	Sí	I haven't had any negative experiences with the company	POSITIVE	0.996141
4	RE/MAX	2021-05-10	5.0	Sí	WE WORK AT THE REMAX YES FRANCISHING IN Paço de Arcos WHERE IS A VERY GOOD PLACE TO WORK; THERES A LOT OF INFORMACION, COLLEGUEES ARE FASTÁTIC AND THE BROOKER IS AN AMAZING PERSON.	POSITIVE	0.999841
5	RE/MAX	2022-08-11	4.0	Sí	If you are a new/newer agent this is not the Brokerage to come to if you need a lot of training and extra help to get you started in your real estate career. If you are a self starter and do not need that then you will be just fine. I knew how to find what I needed and who to talk to for support.	POSITIVE	0.999376
6	RE/MAX	2021-08-31	5.0	Sí	being a realtor sometimes takes a lot of Family time... be sure to learn to balance both	POSITIVE	0.928472
7	RE/MAX	2020-12-29	5.0	Neutral	Not a thing is wrong here	POSITIVE	0.997968
8	Keller-Williams	2018-12-28	5.0	Sí	Work to Build Your Own Brand	POSITIVE	0.998598
9	Colliers	2023-02-22	4.0	Sí	Expensive benefits, demanding partners, return to office	POSITIVE	0.948238
10	Savills	2022-10-02	5.0	Neutral	No negative feedback to provide	POSITIVE	0.991709
11	Realtor-com	2020-01-10	3.0	Neutral	Leadership changes Sales department moved to westlake	POSITIVE	0.937741
12	Century-21	2020-12-02	5.0	Neutral	Great for students looking for extra money Very friendly environment	POSITIVE	0.999615

Revisión manual de los casos discordantes

La revisión manual muestra que las discordancias no se deben exclusivamente a errores del transformer.

Entre los pros clasificados como negativos aparecen respuestas que indican explícitamente que no existe ninguna ventaja, críticas introducidas en el campo incorrecto y textos mixtos en los que una ventaja va acompañada de una limitación. También se observan algunos falsos negativos en frases breves sobre autonomía horaria o disponibilidad de leads.

Entre los cons clasificados como positivos predominan expresiones que niegan la existencia de inconvenientes, como “No cons” o “I haven't had any negative experiences”. También aparecen comentarios positivos introducidos en el campo equivocado y textos que combinan una crítica con una valoración favorable. Existen algunos falsos positivos reales, especialmente en comentarios breves sobre costes y comisiones.

Por tanto, los porcentajes obtenidos son adecuados como control de calidad, pero no deben interpretarse como una medición exacta del sentimiento. La posición del texto en `pros` o `cons`, la negación y el contexto aportan información que un clasificador binario puede no representar correctamente. Se conservarán todos los textos para el modelado de topics, sin eliminar automáticamente los casos discordantes.

---

3. Topic modeling

Decisiones metodológicas

Se utiliza BERTopic porque combina embeddings semánticos con reducción de dimensionalidad y clustering, lo que permite detectar temas incluso cuando las reseñas utilizan palabras diferentes para expresar una misma idea.

Los embeddings se generan con `all-MiniLM-L6-v2`, un modelo ligero para inglés que representa cada texto mediante un vector de 384 dimensiones. Su menor coste computacional permite ejecutar el análisis localmente sin renunciar a una representación semántica.

Se entrenan exactamente dos modelos:

1. Un único modelo conjunto con los pros de RE/MAX y todos sus peers.
2. Un único modelo conjunto con los cons de RE/MAX y todos sus peers.

No se entrena un modelo independiente por empresa, porque sus identificadores de topic no serían comparables.

HDBSCAN puede asignar el topic `-1` a los textos que no encajan de forma suficientemente clara en ningún grupo. Estos textos se conservarán como `Sin asignar` y se incluirán en el denominador de los porcentajes. De esta forma, una empresa con más outliers no verá inflado artificialmente el peso de los topics asignados. La categoría `Sin asignar` se mostrará como control de calidad, pero no se considerará una categoría de negocio ni se utilizará en la matriz final de priorización.

In [18]:
```
# Configuración y embedding de los textos para el modelado de topics con BERTopic

from sentence_transformers import SentenceTransformer
from bertopic import BERTopic
from umap import UMAP
from hdbscan import HDBSCAN
from sklearn.feature_extraction.text import CountVectorizer

if torch.backends.mps.is_available():
    DISPOSITIVO_EMBEDDINGS = 'mps'
```

```
elif torch.cuda.is_available():
    DISPOSITIVO_EMBEDDINGS = 'cuda'
else:
    DISPOSITIVO_EMBEDDINGS = 'cpu'

MODELO_EMBEDDINGS = 'sentence-transformers/all-MiniLM-L6-v2'

print(f'Dispositivo para embeddings: {DISPOSITIVO_EMBEDDINGS}')

modelo_embeddings = SentenceTransformer(
    MODELO_EMBEDDINGS,
    device=DISPOSITIVO_EMBEDDINGS,
)

# Longitud suficiente para estos textos y razonable para la ejecución local.
modelo_embeddings.max_seq_length = 256

documentos_pros = df['pros'].fillna('').astype(str).str.strip().tolist()
documentos_cons = df['cons'].fillna('').astype(str).str.strip().tolist()

print(f'Pros: {len(documentos_pros):,}')
print(f'Cons: {len(documentos_cons):,}')
```

```
Dispositivo para embeddings: mps
Pros: 5,006
Cons: 5,006
```

Generación y almacenamiento de embeddings

Esta celda guarda los vectores para no tener que recalcularlos si reiniciamos el kernel

In [19]:

```
# Ruta compatible con notebooks/, raíz del proyecto y Google Colab
MODELS_DIR = (
    Path('../models')
    if Path('../data').exists()
    else Path('models')
)
MODELS_DIR.mkdir(parents=True, exist_ok=True)

RUTA_EMBEDDINGS_PROS = MODELS_DIR / 'embeddings_pros.npy'
RUTA_EMBEDDINGS_CONS = MODELS_DIR / 'embeddings_cons.npy'

if (
    RUTA_EMBEDDINGS_PROS.exists()
    and RUTA_EMBEDDINGS_CONS.exists()
):
```

```
    embeddings_pros = np.load(RUTA_EMBEDDINGS_PROS)
    embeddings_cons = np.load(RUTA_EMBEDDINGS_CONS)

    if (
        len(embeddings_pros) != len(documentos_pros)
        or len(embeddings_cons) != len(documentos_cons)
    ):
        raise ValueError(
            'Los embeddings guardados no corresponden con la muestra actual.'
        )

    print('Embeddings cargados desde disco.')

else:
    embeddings_pros = modelo_embeddings.encode(
        documentos_pros,
        batch_size=64,
        show_progress_bar=True,
        convert_to_numpy=True,
        normalize_embeddings=True,
    )

    embeddings_cons = modelo_embeddings.encode(
        documentos_cons,
        batch_size=64,
        show_progress_bar=True,
        convert_to_numpy=True,
        normalize_embeddings=True,
    )

    np.save(RUTA_EMBEDDINGS_PROS, embeddings_pros)
    np.save(RUTA_EMBEDDINGS_CONS, embeddings_cons)

    print('Embeddings calculados y guardados.')

print('Forma pros:', embeddings_pros.shape)
print('Forma cons:', embeddings_cons.shape)
```

```
Embeddings cargados desde disco.
Forma pros: (5006, 384)
Forma cons: (5006, 384)
```

Configuración BERTopic

Representación de los topics mediante c-TF-IDF

Después de formar los clusters semánticos, BERTopic agrupa los documentos de cada topic y aplica class-based TF-IDF. Este procedimiento identifica los términos y bigramas que distinguen cada tema del resto. CountVectorizer genera las frecuencias y ClassTfidfTransformer, utilizado

por defecto por BERTopic, calcula su relevancia. Por tanto, c-TF-IDF se utiliza para interpretar y etiquetar los temas, mientras que los embeddings, UMAP y HDBSCAN determinan su agrupación.

In [20]:
```python
def crear_modelo_bertopic():
    """Crea una instancia independiente y reproducible de BERTopic."""
    umap_model = UMAP(
        n_neighbors=15,
        n_components=5,
        min_dist=0.0,
        metric='cosine',
        random_state=SEED,
    )

    hdbscan_model = HDBSCAN(
        min_cluster_size=40,
        min_samples=10,
        metric='euclidean',
        cluster_selection_method='eom',
        prediction_data=True,
    )

    vectorizer_model = CountVectorizer(
        stop_words='english',
        ngram_range=(1, 2),
        min_df=5,
    )

    return BERTopic(
        umap_model=umap_model,
        hdbscan_model=hdbscan_model,
        vectorizer_model=vectorizer_model,
        top_n_words=10,
        calculate_probabilities=False,
        verbose=True,
    )
```

Justificación de parámetros BERTopic

La elección de min_cluster_size=40 evita generar microtopics difíciles de interpretar para RRHH, pero permite detectar categorías con un peso cercano al 1% de la muestra.

- n_neighbors=15: equilibrio entre contexto local y patrones compartidos.
- n_components=5: reduce el coste conservando estructura semántica.
- min_dist=0.0: favorece grupos compactos para HDBSCAN.

- min_samples=10: tratamiento conservador del ruido.
- ngram_range=(1, 2): permite expresiones de RR. HH. como work life o commission split.
- min_df=5: elimina términos demasiado anecdóticos.
- top_n_words=10: facilita la revisión manual.
- calculate_probabilities=False: reduce tiempo y memoria porque no utilizamos las probabilidades posteriores.

Entrenamiento conjunto

In [21]:
```
# Un modelo conjunto para los pros de todas las empresas
modelo_topics_pros = crear_modelo_bertopic()

topics_pros, _ = modelo_topics_pros.fit_transform(
    documentos_pros,
    embeddings_pros,
)

df['topic_pros'] = topics_pros

print('Modelo de pros completado.')
```

```
Modelo de pros completado.
```

In [22]:
```
# Un modelo conjunto para los cons de todas las empresas
modelo_topics_cons = crear_modelo_bertopic()

topics_cons, _ = modelo_topics_cons.fit_transform(
    documentos_cons,
    embeddings_cons,
)

df['topic_cons'] = topics_cons

print('Modelo de cons completado.')
```

```
Modelo de cons completado.
```

UMAP y HDBSCAN se ejecutarán principalmente en CPU, aunque los embeddings se hayan generado con MPS.

Diagnóstico inicial de los topics

In [23]:
```
def diagnostico_topics(modelo, topics, nombre):
    informacion = modelo.get_topic_info().copy()
```

```
    n_topics = informacion['Topic'].ne(-1).sum()
    pct_outliers = np.mean(np.asarray(topics) == -1) * 100

    print(f'Modelo: {nombre}')
    print(f'Topics identificados, sin contar -1: {n_topics}')
    print(f'Porcentaje sin asignar: {pct_outliers:.1f}%')

    display(
        informacion[
            ['Topic', 'Count', 'Name', 'Representation']
        ].head(20)
    )

    return informacion


info_topics_pros = diagnostico_topics(
    modelo_topics_pros,
    topics_pros,
    'Pros',
)

info_topics_cons = diagnostico_topics(
    modelo_topics_cons,
    topics_cons,
    'Cons',
)
```

```
Modelo: Pros
Topics identificados, sin contar -1: 30
Porcentaje sin asignar: 28.8%
```

	Topic	Count	Name	Representation
0	-1	1442	-1_good_company_environment_great	[good, company, environment, great, work, peop...
1	0	310	0_hours_flexible_schedule_flexible hours	[hours, flexible, schedule, flexible hours, fl...
2	1	262	1_benefits_pay_salary_bonus	[benefits, pay, salary, bonus, good, money, de...
3	2	260	2_culture_company culture_great culture_cultur...	[culture, company culture, great culture, cult...
4	3	256	3_team_great team_good team_collaborative	[team, great team, good team, collaborative, t...
5	4	249	4_training_great training_good training_traini...	[training, great training, good training, trai...
6	5	226	5_estate_real estate_real_keller	[estate, real estate, real, keller, training, ...
7	6	171	6_agents_new agents_new_agent	[agents, new agents, new, agent, training new,...
8	7	127	7_balance_work life_life_life balance	[balance, work life, life, life balance, workl...
9	8	127	8_brand_recognition_brand recognition_marketing	[brand, recognition, brand recognition, market...
10	9	126	9_people_people work_nice people_nice	[people, people work, nice people, nice, good ...
11	10	122	10_place_place work_great place_good place	[place, place work, great place, good place, w...
12	11	109	11_leadership_management_leaders_ceo	[leadership, management, leaders, ceo, good le...
13	12	108	12_office_nice office_location_nice	[office, nice office, location, nice, good off...
14	13	107	13_growth_career_opportunity_progression	[growth, career, opportunity, progression, pro...
15	14	89	14_staff_support_staff good_friendly staff	[staff, support, staff good, friendly staff, g...
16	15	85	15_broker_brokerage_brokers_brokerages	[broker, brokerage, brokers, brokerages, suppo...
17	16	80	16_commission_commissions_split_commission split	[commission, commissions, split, commission sp...
18	17	74	17_good company_company work_company_work good	[good company, company work, company, work goo...
19	18	72	18_environment_environment work_working enviro...	[environment, environment work, working enviro...

```
Modelo: Cons
Topics identificados, sin contar -1: 25
Porcentaje sin asignar: 20.1%
```

	Topic	Count	Name	Representation
0	-1	1006	-1_team_company_work_management	[team, company, work, management, like, people...
1	0	717	0_management_culture_staff_leadership	[management, culture, staff, leadership, lack,...
2	1	563	1_salary_pay_low_benefits	[salary, pay, low, benefits, low pay, lower, b...
3	2	468	2_hours_long_long hours_work	[hours, long, long hours, work, time, working ...
4	3	189	3_cons_think_dont cons_dont	[cons, think, dont cons, dont, far, really, mo...
5	4	172	4_agents_new agents_new_agent	[agents, new agents, new, agent, mentorship, f...
6	5	171	5_estate_real estate_real_realtors	[estate, real estate, real, realtors, realtorc...
7	6	169	6_commission_commission based_based_100	[commission, commission based, based, 100, sal...
8	7	168	7_think_moment_far_come	[think, moment, far, come, really, come mind, ...
9	8	136	8_growth_room_career_opportunities	[growth, room, career, opportunities, room gro...
10	9	134	9_fees_expensive_monthly_high	[fees, expensive, monthly, high, desk, desk fe...
11	10	113	10_clients_calls_phone_cold	[clients, calls, phone, cold, calling, client,...
12	11	110	11_cons_working_company_downside	[cons, working, company, downside, great, grea...
13	12	106	12_large_company_large company_big	[large, company, large company, big, competiti...
14	13	94	13_brokerage_brokers_broker_brokerages	[brokerage, brokers, broker, brokerages, fees,...
15	14	94	14_office_parking_offices_small	[office, parking, offices, small, space, envir...
16	15	85	15_tech_technology_ceo_company	[tech, technology, ceo, company, systems, chan...
17	16	82	16_split_franchise_splits_commission split	[split, franchise, splits, commission split, f...
18	17	72	17_say_negative_bad_things	[say, negative, bad, things, dont, really, goo...
19	18	65	18_training_lack_learn_learning	[training, lack, learn, learning, overwhelming...

Diagnóstico inicial de BERTopic

El modelo de pros identifica 30 topics y deja sin asignar el 28,8% de los textos. El modelo de cons identifica 25 topics, con un 20,1% de textos sin asignar.

Aunque el porcentaje de outliers es relevante, los topics principales muestran una interpretación semántica clara. En los pros aparecen temas relacionados con flexibilidad, compensación, cultura, equipo, formación, conciliación, marca, liderazgo y desarrollo profesional. En los cons aparecen dirección, remuneración, jornadas, formación de nuevos agentes, comisiones, costes, carrera, tecnología y entorno de oficina.

Se conservarán los outliers como `Sin asignar` y no se forzará su incorporación a un topic. Esta decisión prioriza la precisión de las categorías de negocio frente a una cobertura artificialmente elevada.

Algunos clusters representan respuestas como “no tengo inconvenientes” o textos sin contenido suficiente. Estos se agruparán posteriormente en `Sin contenido informativo` y se excluirán de la interpretación de fortalezas, problemas y prioridades de RRHH, aunque se mantendrán en el denominador de los porcentajes.

Comprobar los outliers por empresa Antes del etiquetado debemos verificar que los outliers no se concentran especialmente en una compañía:

In [24]:
```
outliers_por_empresa = (
    df.assign(
        pros_sin_asignar=df['topic_pros'].eq(-1),
        cons_sin_asignar=df['topic_cons'].eq(-1),
    )
    .groupby('firm', observed=True)
    .agg(
        n_reseñas=('firm', 'size'),
        pct_pros_sin_asignar=(
            'pros_sin_asignar',
            lambda s: s.mean() * 100,
        ),
        pct_cons_sin_asignar=(
            'cons_sin_asignar',
            lambda s: s.mean() * 100,
        ),
    )
    .reindex(FIRMS)
    .round(1)
)

outliers_por_empresa
```

Out[24]:

firm	n_reseñas	pct_pros_sin_asignar	pct_cons_sin_asignar
RE/MAX	1000	23.6	17.4
Keller-Williams	1000	27.2	20.6
Colliers	1000	30.5	21.2
Savills	960	34.8	22.4
Realtor-com	601	29.3	21.6
Century-21	445	26.7	15.5

Preparar la revisión manual de todos los topics

Para etiquetarlos correctamente necesitamos palabras clave y textos representativos, no solo el nombre automático. Creamos la función que nos ayudará a determinarlos

In [25]:

```
def crear_tabla_revision_topics(modelo, informacion, tipo):
    """Crea una tabla con palabras clave y ejemplos representativos."""
    filas = []

    for _, registro in informacion.iterrows():
        topic = int(registro['Topic'])

        if topic == -1:
            continue

        palabras_topic = modelo.get_topic(topic) or []
        palabras = ', '.join(
            palabra for palabra, _ in palabras_topic[:10]
        )

        ejemplos = modelo.get_representative_docs(topic) or []
        ejemplos_limpios = [
            re.sub(r'\s+', ' ', str(texto)).strip()[:250]
            for texto in ejemplos[:3]
        ]

        filas.append({
            'tipo': tipo,
            'topic': topic,
            'n_textos': int(registro['Count']),
            'nombre_automatico': registro['Name'],
```

```
            'palabras_clave': palabras,
            'ejemplo_1': ejemplos_limpios[0] if len(ejemplos_limpios) > 0 else '',
            'ejemplo_2': ejemplos_limpios[1] if len(ejemplos_limpios) > 1 else '',
            'ejemplo_3': ejemplos_limpios[2] if len(ejemplos_limpios) > 2 else '',
        })

    return pd.DataFrame(filas)


revision_topics_pros = crear_tabla_revision_topics(
    modelo_topics_pros,
    info_topics_pros,
    'Pros',
)

revision_topics_cons = crear_tabla_revision_topics(
    modelo_topics_cons,
    info_topics_cons,
    'Cons',
)
```

In [26]:

```
OUTPUTS_DIR = (
    Path('../outputs')
    if Path('../outputs').exists()
    else Path('outputs')
)
OUTPUTS_DIR.mkdir(parents=True, exist_ok=True)

revision_topics_pros.to_csv(
    OUTPUTS_DIR / 'revision_topics_pros.csv',
    index=False,
)

revision_topics_cons.to_csv(
    OUTPUTS_DIR / 'revision_topics_cons.csv',
    index=False,
)

print('Archivos guardados:')
print(OUTPUTS_DIR / 'revision_topics_pros.csv')
print(OUTPUTS_DIR / 'revision_topics_cons.csv')
```

```
Archivos guardados:
../outputs/revision_topics_pros.csv
../outputs/revision_topics_cons.csv
```

In [27]:

```
# Mostramos las tablas guardadas.
```

```
with pd.option_context(
    'display.max_rows', 40,
    'display.max_colwidth', 180,
):
    display(revision_topics_pros)
    display(revision_topics_cons)
```

	tipo	topic	n_textos	nombre_automatico	palabras_clave	ejemplo_1	ejemplo_2	ejemplo_3
0	Pros	0	310	0_hours_flexible_schedule_flexible hours	hours, flexible, schedule, flexible hours, flexible schedule, home, work home, work, boss, freedom	Flexible Hours Could work from home or in office	Flexible hours for a school schedule	work from home, flexible hours
1	Pros	1	262	1_benefits_pay_salary_bonus	benefits, pay, salary, bonus, good, money, decent, good pay, good salary, great benefits	Good pay and good benefits	The benefits and pay are decent.	Benefits are terrific. Pay seems to be normal.
2	Pros	2	260	2_culture_company culture_great culture_culture great	culture, company culture, great culture, culture great, good culture, culture good, great, great people, balance, good	Great diversity and company culture	Nothing, the culture is toxic	Great ethos and culture
3	Pros	3	256	3_team_great team_good team_collaborative	team, great team, good team, collaborative, teams, team good, team great, team environment, team work, great	Good team, consistent work flow	You get to work independently while being in a “team”	The team is versatile and good.
4	Pros	4	249	4_training_great training_good training_training support	training, great training, good training, training support, support, great, training great, training good, lots training, lots	Training training training training training	Training alike to receiving an MBA	Training is above and beyond
5	Pros	5	226	5_estate_real estate_real_keller	estate, real estate, real, keller, training, business, industry, agents, company, new	Globally dominant real estate company	Real Estate is very good	This is a great real estate company
6	Pros	6	171	6_agents_new agents_new_agent	agents, new agents, new, agent, training new, training, great training, great, help, program	Great training for new agents	Great agents still with them	Great Agents that always take up for others.
7	Pros	7	127	7_balance_work life_life_life balance	balance, work life, life, life balance, worklife balance, worklife, work, balance good, good work, balance great	Mostly Good work life balance	Good work-life balance and well stocked fridge	Work life balance is enforced
8	Pros	8	127	8_brand_recognition_brand recognition_marketing	brand, recognition, brand recognition, marketing, known, strong, franchise, national, recognized, global	brand recognition and great initial support	some marketing and brand recognition	Recognizable brand identity behind you.
9	Pros	9	126	9_people_people work_nice people_nice	people, people work, nice people, nice, good people, great people, people nice, work, work good, people friendly	Nice people to work with	nice people to work with	Nice people to work with

	tipo	topic	n_textos	nombre_automatico	palabras_clave	ejemplo_1	ejemplo_2	ejemplo_3
10	Pros	10	122	10_place_place work_great place_good place	place, place work, great place, good place, work, work great, great, work good, place learn, good	They are a great place to work.	Great place to work at	The place was great place to work
11	Pros	11	109	11_leadership_management_leaders_ceo	leadership, management, leaders, ceo, good leadership, great leadership, employees, team, strong, focus	Great leadership, Great work environment and supportive management.	Good leadership and support from management	Leadership roles , People Management,
12	Pros	12	108	12_office_nice office_location_nice	office, nice office, location, nice, good office, office great, great office, office location, facilities, offices	It has presence globally with Singapore office in downtown.	Office in HK is conveniently located	- Office closer to transportation
13	Pros	13	107	13_growth_career_opportunity_progression	growth, career, opportunity, progression, projects, opportunities, room, grow, development, lots	Great opportunity at career progression	Great growth and career development	Career progression opportunities are there...
14	Pros	14	89	14_staff_support_staff good_friendly staff	staff, support, staff good, friendly staff, great staff, supportive, friendly, office, great support, good support	Everything Good.. All staff good and supportive.. Friendly environment	The comradery between the staff.	good amount of staff here
15	Pros	15	85	15_broker_brokerage_brokers_brokerages	broker, brokerage, brokers, brokerages, support, agents, best, cre, training, great	Great Brokerage with an extremely knowledgeable broker. Great office and counterparts	Chris Beresford is a great broker	Training Broker great master Minds
16	Pros	16	80	16_commission_commissions_split_commission split	commission, commissions, split, commission split, uncapped, splits, structure, flexible hours, hours, potential	No micromanagement, great commission split.	Commission was amazing and so was training!	None at all. Its all commission
17	Pros	17	74	17_good company_company work_company_work good	good company, company work, company, work good, company good, good, work, bad, overall, fair	A good company to work for	Good company to work for	Good company to work for.
18	Pros	18	72	18_environment_environment work_working environment_working	environment, environment work, working environment, working, good environment, fun, environment good, work environment, fun environment, good working	Awesome working environment to work with	Fun working environment and shared backgrounds	A relaxed working environment to work.

	tipo	topic	n_textos	nombre_automatico	palabras_clave	ejemplo_1	ejemplo_2	ejemplo_3
19	Pros	19	68	19_experience_learning_lot_learn	experience, learning, lot, learn, learning experience, learned, learned lot, good learning, good experience, gained	Better learning experience at company	Learning and Experience on a large breadth of assets.	You get a lot of learning experience
20	Pros	20	66	20_flexibility_flexible_flexible work_flexible working	flexibility, flexible, flexible work, flexible working, environment flexible, working, environment, work, independent, entrepreneurial	very flexible working environment to me	There was a lot of flexibility	Flexibility at work and office
21	Pros	21	65	21_great company_company work_company_work great	great company, company work, company, work great, company great, great, work, excellent company, amazing, excellent	Great company to work for!	Great company to work for.	Great company to work for
22	Pros	22	62	22_company_big company_large company_big	company, big company, large company, big, large, company lots, global, growing, international, opportunities	Big name company to work for	big company, BEING FORCED TO REVIEW SO I CAN CONTINUE MY JOB SERACH	Big company, support for APC
23	Pros	23	58	23_colleagues_friendly_colleagues friendly_colleagues good	colleagues, friendly, colleagues friendly, colleagues good, environment, nice colleagues, nice, work environment, great colleagues, working environment	A few sincere, nice and competent colleagues. Other than that, none.	Some friendly colleagues to work with	There are some friendly colleagues
24	Pros	24	56	24_think_dont_say_time	think, dont, say, time, mind, talk, zero, sure, come, really	Nothing I can think of	nothing that I can think of	can't think of anything sorry
25	Pros	25	52	25_atmosphere_great atmosphere_people_nice people	atmosphere, great atmosphere, people, nice people, great people, nice, atmosphere great, environment, people nice, working environment	Great atmosphere to work in	Great atmosphere and great people!	Great people great atmosphere and a productive work experiecne
26	Pros	26	51	26_sales_network_networking_help	sales, network, networking, help, professional, exposure, want, training, good, networking opportunities	Sales enablement is a keystone to my success at RDC. Salesforce Lightening, Gong, Auto Dialer and support for all the tools included. Quality products being sold. Retention rat...	Learning to operate as self-employed, many sales trainings from top ranking sales gurus, 8 years of real sales experience	Experience, annual sales, training, sales materials

	tipo	topic	n_textos	nombre_automatico	palabras_clave	ejemplo_1	ejemplo_2	ejemplo_3
27	Pros	27	45	27_remax_real_real estate_estate	remax, real, real estate, estate, agents, franchise, working, higher, fee, great place	It's REMAX the best name in the biz	Remax training is second to none and never ends.	Nothing period for the Remax Allegiance
28	Pros	28	41	28_tools_lead_marketing_lots	tools, lead, marketing, lots, leads, technology, support, great support, tools great, need	Family like atmosphere, great support, lots of built in technology and lead generation tools	great support. lots of tools for marketing	Tools for lead generation, marketing materials
29	Pros	29	40	29_good good_good_love_good great	good good, good, love, good great, say, enjoyed, okay, great great, ok, better	very good very good very good	good and good and good	Good very good good very

	tipo	topic	n_textos	nombre_automatico	palabras_clave	ejemplo_1	ejemplo_2	ejemplo_3
0	Cons	0	717	0_management_culture_staff_leadership	management, culture, staff, leadership, lack, turnover, employees, toxic, team, hr	lack of communication from management to staff	-Private school boy's club culture -Depending on which team you are in, bullying/harassment often occurs. Particularly in the Residential property team, it has become very toxi...	- TOXIC work culture. Upper management does not listen and/or care. - Harassment is reported and then "swept under the rug". Discipline at worst is a "slap on the hand". Any ot...
1	Cons	1	563	1_salary_pay_low_benefits	salary, pay, low, benefits, low pay, lower, base, bonus, salaries, compensation	The pay for admins was very low	Low salary for the amount of work you do.	low Salary as per designation.
2	Cons	2	468	2_hours_long_long hours_work	hours, long, long hours, work, time, working hours, working, overtime, stressful, workload	Long hours - but my choice	you have to work long hours	Long hours That is all
3	Cons	3	189	3_cons_think_dont cons_dont	cons, think, dont cons, dont, far, really, moment, pros, experience, list	There are not cons at all	There are not many cons	nothing in the cons till now
4	Cons	4	172	4_agents_new agents_new_agent	agents, new agents, new, agent, mentorship, fees, rude, training, classes, business	Some Agents are not seasoned	Too many agents not enough inventory	Some of the agents are arrogant a*holes.
5	Cons	5	171	5_estate_real estate_real_realtors	estate, real estate, real, realtors, realtorcom, market, agent, business, agents, make	Real estate subject to market volatility	Real Estate Cycles a lot	Real estate agents are always on the clock and are at the mercy of the real estate market.
6	Cons	6	169	6_commission_commission based_based_100	commission, commission based, based, 100, salary, commissions, pay, money, make, structure	They keep too much of your commission	they take 28% of your commission	Commission based only I want something with both salary and commission.
7	Cons	7	168	7_think_moment_far_come	think, moment, far, come, really, come mind, mind, mention, non, havent	None that I can think of	None that I can think of	None that I can think of.
8	Cons	8	136	8_growth_room_career_opportunities	growth, room, career, opportunities, room growth, progression, opportunity, grow, growth opportunities, advancement	not much room for growth	No room For growth at All	Not enough room for career growth

	tipo	topic	n_textos	nombre_automatico	palabras_clave	ejemplo_1	ejemplo_2	ejemplo_3
9	Cons	9	134	9_fees_expensive_monthly_high	fees, expensive, monthly, high, desk, desk fees, fee, monthly fees, high fees, month	Take your Fees and do nothing.	Fees can be kinda expensive	many fees, desk fees, paper fees, etc
10	Cons	10	113	10_clients_calls_phone_cold	clients, calls, phone, cold, calling, client, center, cold calling, day, customers	Waiting on funds, dead ends, fusy clients	No Clients, no infrastructure on the tenant representation and research side	This job means hitting the phones Angry customers who think we are cold calling them Many calls to secure one listing
11	Cons	11	110	11_cons_working_company_downside	cons, working, company, downside, great, great company, place work, great place, work, place	I have no cons for this company.	I didn't have any cons with the company.	No Cons for working for this company
12	Cons	12	106	12_large_company_large company_big	large, company, large company, big, competitive, corporate, lost, feel, small, international	Very large company to work for	Such a large company you get lost	Large company, can take time to price yourself
13	Cons	13	94	13_brokerage_brokers_broker_brokerages	brokerage, brokers, broker, brokerages, fees, like, expensive, culture, different, compared	It was too geared towards the power brokers	Brokerage fees are slightly more than other brokerages I have looked into.	I was in brokerage: - Commission only - Healthcare isn't favorable for entry-level brokers - Company tends to only favor the heavy-hitters in the industry
14	Cons	14	94	14_office_parking_offices_small	office, parking, offices, small, space, environment, location, people, head, need	Each office is privately own	- There's no ping pong table in the office	Not many amenities in office
15	Cons	15	85	15_tech_technology_ceo_company	tech, technology, ceo, company, systems, change, changes, outdated, lots, software	Tech debt is not handled that well	Frequent leadership and direction changes in Technology Political agendas Heavy technology debt, lots of legacy systems and services	They think of themselves as a tech company, but have no experience in real tech. The turnover rate has exploded. The company is not building people or careers - they're maximiz...
16	Cons	16	82	16_split_franchise_splits_commission split	split, franchise, splits, commission split, fee, commission, fees, high, cap, brokerage	commission split is high for a new agent no training franchise fee is high office was not accessible to meet clients desk fees are high	commission split and brokerage fees.	The Commission split is very high.

	tipo	topic	n_textos	nombre_automatico	palabras_clave	ejemplo_1	ejemplo_2	ejemplo_3
17	Cons	17	72	17_say_negative_bad_things	say, negative, bad, things, dont, really, good, thing, think, feedback	I don’t have anything negative to say	I have nothing negative to say	I don't have anything negative to say
18	Cons	18	65	18_training_lack_learn_learning	training, lack, learn, learning, overwhelming, support, resources, skills, little, development	Training or lack there of	Pressures, lack of training, sink or swim	Training regimen doesn’t work for everyone.
19	Cons	19	58	19_leads_lead_generation_calling	leads, lead, generation, calling, constantly changing, generate, provide, constantly, use, provided	Leads Referrals Teamwork Graduation Training	You have to ha w overflowing of leads.	on your own, no leads
20	Cons	20	57	20_great_place_love_place work	great, place, love, place work, great company, company work, working, work, amazing, enjoy	nothing this place is great	None - Great place to work	There aren't any. Great place to work.
21	Cons	21	46	21_good_great company_place work_place	good, great company, place work, place, great, good company, work, company work, company, enjoyed	It is a great company to work for.	Great company would work there	its a great company to work for
22	Cons	22	46	22_share_mind_comes_add	share, mind, comes, add, think, mentioned, moment, time, things, include	- Nothing drastic that comes to mind at all.	Nothing comes to mind here	Nothing egregious comes to mind.
23	Cons	23	45	23_company_say_bad_negative	company, say, bad, negative, good, wrong, feedback, far, great, customer	Nothing bad to say about this company.	Nothing much bad to say about the company	Nothing bad to say about this company
24	Cons	24	40	24_balance_work life_life balance_life	balance, work life, life balance, life, work, worklife balance, worklife, zero, pay work, going	No Work-life balance No & Job Security	There is no work life balance in this company	no work and life balance

Distribución de los textos sin asignar

RE/MAX presenta un 23,6% de outliers en pros y un 17,4% en cons. Ambos porcentajes son inferiores a los observados en la mayoría de los peers, por lo que el modelo no parece tener una dificultad especial para interpretar sus reseñas.

Savills presenta el porcentaje más elevado de pros sin asignar, con un 34,8%. Para evitar que las diferencias de cobertura distorsionen la comparación, los porcentajes de las categorías se calcularán sobre el total de reseñas de cada empresa, incluyendo `Sin asignar` en el denominador.

Los outliers se conservarán para mantener la trazabilidad, pero no se utilizarán como evidencia de una fortaleza o un problema de RRHH.

---

4. Interpretación temática y comparación con los peers

Mapeo manual a categorías de negocio

In [28]:
```
CULTURA = 'Cultura, liderazgo y equipo'
FLEXIBILIDAD = 'Flexibilidad, conciliación y carga de trabajo'
COMPENSACION = 'Compensación, comisiones y costes'
FORMACION = 'Formación, onboarding y soporte'
CARRERA = 'Carrera y desarrollo'
MARCA = 'Marca y reputación'
VENTAS = 'Ventas, clientes y captación'
TECNOLOGIA = 'Tecnología, herramientas y procesos'
OFICINAS = 'Oficinas y entorno físico'
MODELO_NEGOCIO = 'Modelo de negocio y mercado'
ESTRUCTURA = 'Estructura y organización'
GENERAL = 'Valoración general sin detalle'
SIN_CONTENIDO = 'Sin contenido informativo'
SIN_ASIGNAR = 'Sin asignar'
```

In [29]:
```
# Mapeo de Pros

MAPEO_TOPICS_PROS = {
    -1: SIN_ASIGNAR,
    0: FLEXIBILIDAD,
    1: COMPENSACION,
    2: CULTURA,
    3: CULTURA,
    4: FORMACION,
    5: MARCA,
    6: FORMACION,
    7: FLEXIBILIDAD,
    8: MARCA,
    9: CULTURA,
```

```
    10: GENERAL,
    11: CULTURA,
    12: OFICINAS,
    13: CARRERA,
    14: CULTURA,
    15: FORMACION,
    16: COMPENSACION,
    17: GENERAL,
    18: CULTURA,
    19: CARRERA,
    20: FLEXIBILIDAD,
    21: GENERAL,
    22: MARCA,
    23: CULTURA,
    24: SIN_CONTENIDO,
    25: CULTURA,
    26: VENTAS,
    27: MARCA,
    28: TECNOLOGIA,
    29: GENERAL,
}
```

In [30]:

```
# Mapeo de Cons

MAPEO_TOPICS_CONS = {
    -1: SIN_ASIGNAR,
    0: CULTURA,
    1: COMPENSACION,
    2: FLEXIBILIDAD,
    3: SIN_CONTENIDO,
    4: FORMACION,
    5: MODELO_NEGOCIO,
    6: COMPENSACION,
    7: SIN_CONTENIDO,
    8: CARRERA,
    9: COMPENSACION,
    10: VENTAS,
    11: SIN_CONTENIDO,
    12: ESTRUCTURA,
    13: COMPENSACION,
    14: OFICINAS,
    15: TECNOLOGIA,
    16: COMPENSACION,
    17: SIN_CONTENIDO,
    18: FORMACION,
    19: VENTAS,
    20: SIN_CONTENIDO,
    21: SIN_CONTENIDO,
```

```
    22: SIN_CONTENIDO,
    23: SIN_CONTENIDO,
    24: FLEXIBILIDAD,
}
```

In [31]:
```
# Validación y asignación de categorías a los topics


topics_pros_observados = set(df['topic_pros'].unique())
topics_cons_observados = set(df['topic_cons'].unique())

topics_pros_sin_mapear = (
    topics_pros_observados - set(MAPEO_TOPICS_PROS)
)
topics_cons_sin_mapear = (
    topics_cons_observados - set(MAPEO_TOPICS_CONS)
)

assert not topics_pros_sin_mapear, (
    f'Topics de pros sin mapear: {topics_pros_sin_mapear}'
)
assert not topics_cons_sin_mapear, (
    f'Topics de cons sin mapear: {topics_cons_sin_mapear}'
)

df['categoria_pros'] = df['topic_pros'].map(MAPEO_TOPICS_PROS)
df['categoria_cons'] = df['topic_cons'].map(MAPEO_TOPICS_CONS)

assert df['categoria_pros'].notna().all()
assert df['categoria_cons'].notna().all()

print('Todos los topics han sido asignados a una categoría.')
```

```
Todos los topics han sido asignados a una categoría.
```

In [32]:
```
# Revisión visual del mapeo de topics a categorías

revision_mapeo_pros = (
    revision_topics_pros[
        ['topic', 'n_textos', 'palabras_clave', 'ejemplo_1']
    ]
    .assign(
        categoria=lambda x: x['topic'].map(MAPEO_TOPICS_PROS)
    )
    [['topic', 'n_textos', 'categoria', 'palabras_clave', 'ejemplo_1']]
)

revision_mapeo_cons = (
```

```
    revision_topics_cons[
        ['topic', 'n_textos', 'palabras_clave', 'ejemplo_1']
    ]
    .assign(
        categoria=lambda x: x['topic'].map(MAPEO_TOPICS_CONS)
    )
    [['topic', 'n_textos', 'categoria', 'palabras_clave', 'ejemplo_1']]
)

with pd.option_context(
    'display.max_rows', 40,
    'display.max_colwidth', 160,
):
    display(revision_mapeo_pros)
    display(revision_mapeo_cons)
```

	topic	n_textos	categoria	palabras_clave	ejemplo_1
0	0	310	Flexibilidad, conciliación y carga de trabajo	hours, flexible, schedule, flexible hours, flexible schedule, home, work home, work, boss, freedom	Flexible Hours Could work from home or in office
1	1	262	Compensación, comisiones y costes	benefits, pay, salary, bonus, good, money, decent, good pay, good salary, great benefits	Good pay and good benefits
2	2	260	Cultura, liderazgo y equipo	culture, company culture, great culture, culture great, good culture, culture good, great, great people, balance, good	Great diversity and company culture
3	3	256	Cultura, liderazgo y equipo	team, great team, good team, collaborative, teams, team good, team great, team environment, team work, great	Good team, consistent work flow
4	4	249	Formación, onboarding y soporte	training, great training, good training, training support, support, great, training great, training good, lots training, lots	Training training training training training
5	5	226	Marca y reputación	estate, real estate, real, keller, training, business, industry, agents, company, new	Globally dominant real estate company
6	6	171	Formación, onboarding y soporte	agents, new agents, new, agent, training new, training, great training, great, help, program	Great training for new agents
7	7	127	Flexibilidad, conciliación y carga de trabajo	balance, work life, life, life balance, worklife balance, worklife, work, balance good, good work, balance great	Mostly Good work life balance
8	8	127	Marca y reputación	brand, recognition, brand recognition, marketing, known, strong, franchise, national, recognized, global	brand recognition and great initial support
9	9	126	Cultura, liderazgo y equipo	people, people work, nice people, nice, good people, great people, people nice, work, work good, people friendly	Nice people to work with
10	10	122	Valoración general sin detalle	place, place work, great place, good place, work, work great, great, work good, place learn, good	They are a great place to work.
11	11	109	Cultura, liderazgo y equipo	leadership, management, leaders, ceo, good leadership, great leadership, employees, team, strong, focus	Great leadership, Great work environment and supportive management.
12	12	108	Oficinas y entorno físico	office, nice office, location, nice, good office, office great, great office, office location, facilities, offices	It has presence globally with Singapore office in downtown.
13	13	107	Carrera y desarrollo	growth, career, opportunity, progression, projects, opportunities, room, grow, development, lots	Great opportunity at career progression
14	14	89	Cultura, liderazgo y equipo	staff, support, staff good, friendly staff, great staff, supportive, friendly, office, great support, good support	Everything Good.. All staff good and supportive.. Friendly environment
15	15	85	Formación, onboarding y soporte	broker, brokerage, brokers, brokerages, support, agents, best, cre, training, great	Great Brokerage with an extremely knowledgeable broker. Great office and counterparts
16	16	80	Compensación, comisiones y costes	commission, commissions, split, commission split, uncapped, splits, structure, flexible hours, hours, potential	No micromanagement, great commission split.
17	17	74	Valoración general sin detalle	good company, company work, company, work good, company good, good, work, bad, overall, fair	A good company to work for
18	18	72	Cultura, liderazgo y equipo	environment, environment work, working environment, working, good environment, fun, environment good, work environment, fun environment, good working	Awesome working environment to work with

	topic	n_textos	categoria	palabras_clave	ejemplo_1
19	19	68	Carrera y desarrollo	experience, learning, lot, learn, learning experience, learned, learned lot, good learning, good experience, gained	Better learning experience at company
20	20	66	Flexibilidad, conciliación y carga de trabajo	flexibility, flexible, flexible work, flexible working, environment flexible, working, environment, work, independent, entrepreneurial	very flexible working environment to me
21	21	65	Valoración general sin detalle	great company, company work, company, work great, company great, great, work, excellent company, amazing, excellent	Great company to work for!
22	22	62	Marca y reputación	company, big company, large company, big, large, company lots, global, growing, international, opportunities	Big name company to work for
23	23	58	Cultura, liderazgo y equipo	colleagues, friendly, colleagues friendly, colleagues good, environment, nice colleagues, nice, work environment, great colleagues, working environment	A few sincere, nice and competent colleagues. Other than that, none.
24	24	56	Sin contenido informativo	think, dont, say, time, mind, talk, zero, sure, come, really	Nothing I can think of
25	25	52	Cultura, liderazgo y equipo	atmosphere, great atmosphere, people, nice people, great people, nice, atmosphere great, environment, people nice, working environment	Great atmosphere to work in
26	26	51	Ventas, clientes y captación	sales, network, networking, help, professional, exposure, want, training, good, networking opportunities	Sales enablement is a keystone to my success at RDC. Salesforce Lightening, Gong, Auto Dialer and support for all the tools included. Quality products being...
27	27	45	Marca y reputación	remax, real, real estate, estate, agents, franchise, working, higher, fee, great place	It’s REMAX the best name in the biz
28	28	41	Tecnología, herramientas y procesos	tools, lead, marketing, lots, leads, technology, support, great support, tools great, need	Family like atmosphere, great support, lots of built in technology and lead generation tools
29	29	40	Valoración general sin detalle	good good, good, love, good great, say, enjoyed, okay, great great, ok, better	very good very good very good

	topic	n_textos	categoria	palabras_clave	ejemplo_1
0	0	717	Cultura, liderazgo y equipo	management, culture, staff, leadership, lack, turnover, employees, toxic, team, hr	lack of communication from management to staff
1	1	563	Compensación, comisiones y costes	salary, pay, low, benefits, low pay, lower, base, bonus, salaries, compensation	The pay for admins was very low
2	2	468	Flexibilidad, conciliación y carga de trabajo	hours, long, long hours, work, time, working hours, working, overtime, stressful, workload	Long hours - but my choice
3	3	189	Sin contenido informativo	cons, think, dont cons, dont, far, really, moment, pros, experience, list	There are not cons at all
4	4	172	Formación, onboarding y soporte	agents, new agents, new, agent, mentorship, fees, rude, training, classes, business	Some Agents are not seasoned
5	5	171	Modelo de negocio y mercado	estate, real estate, real, realtors, realtorcom, market, agent, business, agents, make	Real estate subject to market volatility
6	6	169	Compensación, comisiones y costes	commission, commission based, based, 100, salary, commissions, pay, money, make, structure	They keep too much of your commission
7	7	168	Sin contenido informativo	think, moment, far, come, really, come mind, mind, mention, non, havent	None that I can think of
8	8	136	Carrera y desarrollo	growth, room, career, opportunities, room growth, progression, opportunity, grow, growth opportunities, advancement	not much room for growth
9	9	134	Compensación, comisiones y costes	fees, expensive, monthly, high, desk, desk fees, fee, monthly fees, high fees, month	Take your Fees and do nothing.
10	10	113	Ventas, clientes y captación	clients, calls, phone, cold, calling, client, center, cold calling, day, customers	Waiting on funds, dead ends, fusy clients
11	11	110	Sin contenido informativo	cons, working, company, downside, great, great company, place work, great place, work, place	I have no cons for this company.
12	12	106	Estructura y organización	large, company, large company, big, competitive, corporate, lost, feel, small, international	Very large company to work for
13	13	94	Compensación, comisiones y costes	brokerage, brokers, broker, brokerages, fees, like, expensive, culture, different, compared	It was too geared towards the power brokers
14	14	94	Oficinas y entorno físico	office, parking, offices, small, space, environment, location, people, head, need	Each office is privately own
15	15	85	Tecnología, herramientas y procesos	tech, technology, ceo, company, systems, change, changes, outdated, lots, software	Tech debt is not handled that well
16	16	82	Compensación, comisiones y costes	split, franchise, splits, commission split, fee, commission, fees, high, cap, brokerage	commission split is high for a new agent no training franchise fee is high office was not accessible to meet clients desk fees are high
17	17	72	Sin contenido informativo	say, negative, bad, things, dont, really, good, thing, think, feedback	I don’t have anything negative to say
18	18	65	Formación, onboarding y soporte	training, lack, learn, learning, overwhelming, support, resources, skills, little, development	Training or lack there of

	topic	n_textos	categoria	palabras_clave	ejemplo_1
19	19	58	Ventas, clientes y captación	leads, lead, generation, calling, constantly changing, generate, provide, constantly, use, provided	Leads Referrals Teamwork Graduation Training
20	20	57	Sin contenido informativo	great, place, love, place work, great company, company work, working, work, amazing, enjoy	nothing this place is great
21	21	46	Sin contenido informativo	good, great company, place work, place, great, good company, work, company work, company, enjoyed	It is a great company to work for.
22	22	46	Sin contenido informativo	share, mind, comes, add, think, mentioned, moment, time, things, include	- Nothing drastic that comes to mind at all.
23	23	45	Sin contenido informativo	company, say, bad, negative, good, wrong, feedback, far, great, customer	Nothing bad to say about this company.
24	24	40	Flexibilidad, conciliación y carga de trabajo	balance, work life, life balance, life, work, worklife balance, worklife, zero, pay work, going	No Work-life balance No & Job Security

In [33]:
```
# Porcentaje de reseñas por categoría

ORDEN_CATEGORIAS = [
    CULTURA,
    FLEXIBILIDAD,
    COMPENSACION,
    FORMACION,
    CARRERA,
    MARCA,
    VENTAS,
    TECNOLOGIA,
    OFICINAS,
    MODELO_NEGOCIO,
    ESTRUCTURA,
    GENERAL,
    SIN_CONTENIDO,
    SIN_ASIGNAR,
]


def calcular_porcentajes_categoria(datos, columna_categoria):
    tabla = pd.crosstab(
        datos['firm'],
        datos[columna_categoria],
        normalize='index',
    ) * 100

    tabla = tabla.reindex(
        index=FIRMS,
        columns=ORDEN_CATEGORIAS,
```

```
        fill_value=0,
    )

    assert np.allclose(
        tabla.sum(axis=1),
        100,
    ), 'Los porcentajes no suman 100%.'

    return tabla.round(1)


porcentaje_categorias_pros = calcular_porcentajes_categoria(
    df,
    'categoria_pros',
)

porcentaje_categorias_cons = calcular_porcentajes_categoria(
    df,
    'categoria_cons',
)

print('Categorías en pros (% del total de reseñas):')
display(porcentaje_categorias_pros)

print('Categorías en cons (% del total de reseñas):')
display(porcentaje_categorias_cons)
```

```
Categorías en pros (% del total de reseñas):
```

categoria_pros	Cultura, liderazgo y equipo	Flexibilidad, conciliación y carga de trabajo	Compensación, comisiones y costes	Formación, onboarding y soporte	Carrera y desarrollo	Marca y reputación	Ventas, clientes y captación	Tecnología, herramientas y procesos	Oficinas y entorno físico	Modelo de negocio y mercado	Estructura y organización	Valoración general sin detalle	cor infor
firm													
RE/MAX	14.6	13.1	6.3	10.7	3.0	16.3	1.7	1.5	1.2	0.0	0.0	7.2	
Keller-Williams	14.1	7.2	3.3	25.9	2.4	11.4	0.8	1.0	1.0	0.0	0.0	4.8	
Colliers	28.6	9.4	5.6	3.3	6.3	4.6	0.9	0.2	4.1	0.0	0.0	5.2	
Savills	26.2	7.9	7.1	3.3	3.6	5.7	0.5	0.0	3.5	0.0	0.0	5.6	
Realtor-com	20.6	13.6	15.3	1.7	2.3	6.0	1.8	0.3	0.8	0.0	0.0	6.7	
Century-21	16.4	10.8	6.7	14.4	2.0	10.3	0.2	2.7	1.3	0.0	0.0	7.9	

```
Categorías en cons (% del total de reseñas):
```

categoria_cons	Cultura, liderazgo y equipo	Flexibilidad, conciliación y carga de trabajo	Compensación, comisiones y costes	Formación, onboarding y soporte	Carrera y desarrollo	Marca y reputación	Ventas, clientes y captación	Tecnología, herramientas y procesos	Oficinas y entorno físico	Modelo de negocio y mercado	Estructura y organización	Valoración general sin detalle	co infor
firm													
RE/MAX	6.9	10.8	27.2	6.1	2.4	0.0	3.3	1.6	2.1	5.0	1.3	0.0	
Keller-Williams	6.9	6.8	23.9	10.3	1.4	0.0	4.0	1.0	2.2	5.8	1.3	0.0	
Colliers	20.8	11.4	19.1	1.2	5.0	0.0	1.4	0.9	2.2	0.5	2.4	0.0	
Savills	18.9	14.0	17.7	2.0	3.0	0.0	1.8	1.1	1.9	1.0	4.1	0.0	
Realtor-com	27.0	7.2	9.0	0.8	2.7	0.0	8.8	5.0	0.3	3.7	2.0	0.0	
Century-21	6.3	9.2	26.1	8.3	0.7	0.0	3.1	2.0	2.0	5.8	1.1	0.0	

Balance neto y gap frente a los peers

In [34]:
```
CATEGORIAS_NEGOCIO = [
    CULTURA,
    FLEXIBILIDAD,
    COMPENSACION,
    FORMACION,
    CARRERA,
    MARCA,
    VENTAS,
    TECNOLOGIA,
    OFICINAS,
    MODELO_NEGOCIO,
    ESTRUCTURA,
]


def calcular_porcentajes_exactos(datos, columna_categoria):
    tabla = pd.crosstab(
        datos['firm'],
        datos[columna_categoria],
        normalize='index',
    ) * 100

    return tabla.reindex(
        index=FIRMS,
        columns=ORDEN_CATEGORIAS,
        fill_value=0,
    )
```

```python
porcentaje_pros_exacto = calcular_porcentajes_exactos(
    df,
    'categoria_pros',
)

porcentaje_cons_exacto = calcular_porcentajes_exactos(
    df,
    'categoria_cons',
)

media_peers_pros = porcentaje_pros_exacto.loc[PEERS].mean()
media_peers_cons = porcentaje_cons_exacto.loc[PEERS].mean()

balance_remax = (
    porcentaje_pros_exacto.loc[TARGET]
    - porcentaje_cons_exacto.loc[TARGET]
)

balance_peers = media_peers_pros - media_peers_cons

comparacion_categorias = pd.DataFrame({
    'Pros RE/MAX (%)': porcentaje_pros_exacto.loc[TARGET],
    'Cons RE/MAX (%)': porcentaje_cons_exacto.loc[TARGET],
    'Balance RE/MAX': balance_remax,
    'Pros peers (%)': media_peers_pros,
    'Cons peers (%)': media_peers_cons,
    'Balance peers': balance_peers,
})

comparacion_categorias['Gap balance vs. peers'] = (
    comparacion_categorias['Balance RE/MAX']
    - comparacion_categorias['Balance peers']
)

comparacion_negocio = (
    comparacion_categorias
    .loc[CATEGORIAS_NEGOCIO]
    .sort_values('Gap balance vs. peers', ascending=False)
)

comparacion_negocio.round(2)
```

Out[34]:

	Pros RE/MAX (%)	Cons RE/MAX (%)	Balance RE/MAX	Pros peers (%)	Cons peers (%)	Balance peers	Gap balance vs. peers
Marca y reputación	16.3	0.0	16.3	7.61	0.00	7.61	8.69
Cultura, liderazgo y equipo	14.6	6.9	7.7	21.20	15.96	5.24	2.46
Flexibilidad, conciliación y carga de trabajo	13.1	10.8	2.3	9.79	9.71	0.08	2.22
Ventas, clientes y captación	1.7	3.3	-1.6	0.86	3.83	-2.97	1.37
Tecnología, herramientas y procesos	1.5	1.6	-0.1	0.85	2.01	-1.17	1.07
Estructura y organización	0.0	1.3	-1.3	0.00	2.18	-2.18	0.88
Carrera y desarrollo	3.0	2.4	0.6	3.34	2.55	0.79	-0.19
Formación, onboarding y soporte	10.7	6.1	4.6	9.72	4.53	5.19	-0.59
Oficinas y entorno físico	1.2	2.1	-0.9	2.16	1.73	0.44	-1.34
Modelo de negocio y mercado	0.0	5.0	-5.0	0.00	3.37	-3.37	-1.63
Compensación, comisiones y costes	6.3	27.2	-20.9	7.61	19.15	-11.55	-9.35

In [35]:
```
# Guardamos la tabla
comparacion_negocio.to_csv(
    OUTPUTS_DIR / 'comparacion_categorias_remax_vs_peers.csv',
)

print(
    OUTPUTS_DIR /
    'comparacion_categorias_remax_vs_peers.csv'
)
```

```
../outputs/comparacion_categorias_remax_vs_peers.csv
```

In [36]:
```
# Visualización del GAP competitivo de RE/MAX frente a la media de sus peers

datos_gap = (
    comparacion_negocio['Gap balance vs. peers']
    .sort_values()
)

colores = [
    '#2A9D8F' if valor >= 0 else '#E76F51'
    for valor in datos_gap
]

fig, ax = plt.subplots(figsize=(10, 6))
```

```
barras = ax.barh(
    datos_gap.index,
    datos_gap.values,
    color=colores,
)

ax.axvline(
    0,
    color='black',
    linewidth=1,
)

ax.set(
    title='Gap del balance neto de RE/MAX frente a sus peers',
    xlabel='Diferencia en puntos porcentuales',
    ylabel='Categoría de negocio',
)

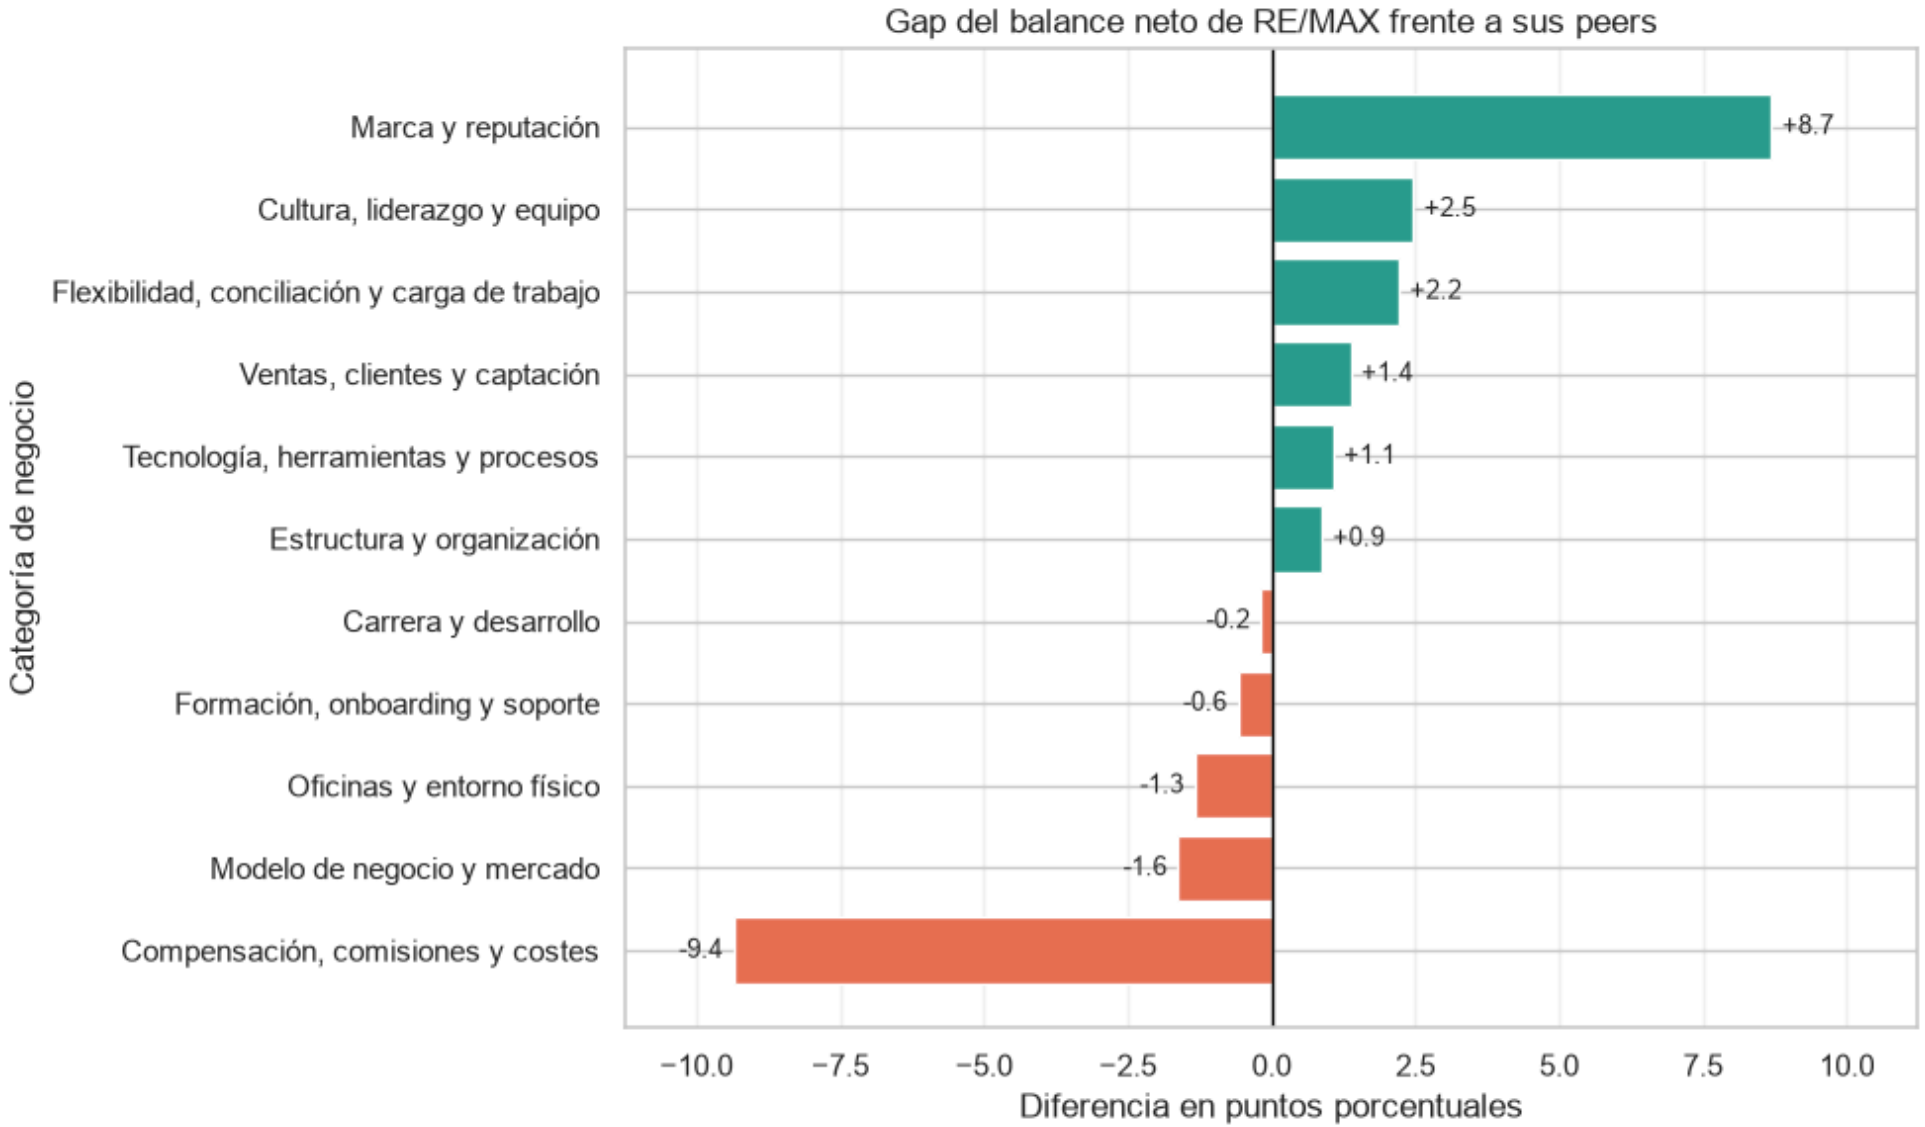
ax.bar_label(
    barras,
    labels=[f'{valor:+.1f}' for valor in datos_gap.values],
    padding=4,
    fontsize=9,
)

margen = max(abs(datos_gap.min()), abs(datos_gap.max())) * 1.2
ax.set_xlim(-margen, margen)
ax.grid(axis='x', alpha=0.25)

plt.tight_layout()

fig.savefig(
    IMAGES_DIR / 'gap_balance_remax_vs_peers.png',
    dpi=160,
    bbox_inches='tight',
)

plt.show()
```



Balance neto y comparación con los peers

La principal fortaleza diferencial de RE/MAX es `Marca y reputación`. La categoría aparece con mucha mayor frecuencia en los pros de RE/MAX que en los de sus peers y no tiene un peso relevante en los cons. El reconocimiento de marca constituye, por tanto, un activo claro para

la atracción de talento.

RE/MAX también presenta ventajas relativas en `Cultura, liderazgo y equipo` y en `Flexibilidad, conciliación y carga de trabajo`. Aunque ambas categorías aparecen en los cons, su balance entre menciones positivas y negativas es más favorable que el de la competencia.

La principal debilidad es `Compensación, comisiones y costes`. Su peso en los cons de RE/MAX es muy superior al observado en los pros y produce una desventaja cercana a nueve puntos porcentuales frente al balance medio de los peers. Esta diferencia es lo suficientemente grande como para considerarla la principal candidata a la matriz de priorización.

También aparecen desventajas menores en `Modelo de negocio y mercado`, `Oficinas y entorno físico` y `Formación, onboarding y soporte`. Estas categorías deberán validarse con el rating y la recomendación antes de considerarlas problemas prioritarios.

Los porcentajes son relativos y se calculan sobre el total de reseñas de cada empresa. Por ello, la interpretación se basa en el balance neto y en la comparación con los peers, no únicamente en el peso de una categoría dentro de los cons.

Contraste con el rating y la recomendación

Una categoría con peso elevado en los cons no constituye necesariamente un problema prioritario. Para validar su impacto se compara el rating medio y el porcentaje de recomendación de las reseñas asociadas a cada categoría con los valores generales de RE/MAX.

Si una categoría representa un problema real, esperamos que sus reseñas presenten un rating inferior y una menor recomendación que el conjunto de la empresa. También se compara su resultado con el obtenido por los peers para esa misma categoría.

In [37]:
```
df_remax = df[df['firm'].eq(TARGET)].copy()
df_peers = df[df['firm'].isin(PEERS)].copy()

rating_general_remax = df_remax['overall_rating'].mean()
recomendacion_general_remax = (
    df_remax['recomienda'].eq('Sí').mean() * 100
)

impacto_remax = (
    df_remax[
        df_remax['categoria_cons'].isin(CATEGORIAS_NEGOCIO)
    ]
    .groupby('categoria_cons', observed=True)
    .agg(
        n_reseñas=('firm', 'size'),
        rating_medio=('overall_rating', 'mean'),
```

```
        pct_recomienda=(
            'recomienda',
            lambda s: s.eq('Sí').mean() * 100,
        ),
    )
)

impacto_remax['peso_en_cons_pct'] = (
    porcentaje_cons_exacto
    .loc[TARGET]
    .reindex(impacto_remax.index)
)

impacto_remax['gap_rating_vs_total_remax'] = (
    impacto_remax['rating_medio']
    - rating_general_remax
)

impacto_remax['gap_recomendacion_vs_total_remax'] = (
    impacto_remax['pct_recomienda']
    - recomendacion_general_remax
)

impacto_remax = impacto_remax.sort_values(
    'gap_rating_vs_total_remax'
)

print(f'Rating general de RE/MAX: {rating_general_remax:.2f}')
print(
    'Recomendación general de RE/MAX: '
    f'{recomendacion_general_remax:.1f}%'
)

impacto_remax.round(2)
```

```
Rating general de RE/MAX: 4.10
Recomendación general de RE/MAX: 42.2%
```

Out[37]:

categoria_cons	n_reseñas	rating_medio	pct_recomienda	peso_en_cons_pct	gap_rating_vs_total_remax	gap_recomendacion_vs_total_remax
Cultura, liderazgo y equipo	69	3.20	30.43	6.9	-0.89	-11.77
Carrera y desarrollo	24	3.79	45.83	2.4	-0.30	3.63
Ventas, clientes y captación	33	3.82	42.42	3.3	-0.28	0.22
Compensación, comisiones y costes	272	3.89	36.40	27.2	-0.21	-5.80
Tecnología, herramientas y procesos	16	3.94	37.50	1.6	-0.16	-4.70
Modelo de negocio y mercado	50	4.10	50.00	5.0	0.00	7.80
Oficinas y entorno físico	21	4.14	47.62	2.1	0.05	5.42
Formación, onboarding y soporte	61	4.20	37.70	6.1	0.10	-4.50
Flexibilidad, conciliación y carga de trabajo	108	4.31	47.22	10.8	0.21	5.02
Estructura y organización	13	4.31	61.54	1.3	0.21	19.34

In [38]:

```
impacto_peers_por_empresa = (
    df_peers[
        df_peers['categoria_cons'].isin(CATEGORIAS_NEGOCIO)
    ]
    .groupby(
        ['firm', 'categoria_cons'],
        observed=True,
    )
    .agg(
        n_reseñas=('firm', 'size'),
        rating_medio=('overall_rating', 'mean'),
        pct_recomienda=(
            'recomienda',
            lambda s: s.eq('Sí').mean() * 100,
        ),
    )
    .reset_index()
)

# Media simple entre empresas para evitar que el peer con más
# observaciones dentro de una categoría domine el resultado.
impacto_peers = (
    impacto_peers_por_empresa
    .groupby('categoria_cons', observed=True)
    .agg(
```

```
        n_empresas_peers=('firm', 'nunique'),
        rating_medio_peers=('rating_medio', 'mean'),
        pct_recomienda_peers=('pct_recomienda', 'mean'),
    )
)

validacion_categorias = impacto_remax.join(
    impacto_peers,
    how='left',
)

validacion_categorias['gap_rating_remax_vs_peers'] = (
    validacion_categorias['rating_medio']
    - validacion_categorias['rating_medio_peers']
)

validacion_categorias['gap_recomendacion_remax_vs_peers'] = (
    validacion_categorias['pct_recomienda']
    - validacion_categorias['pct_recomienda_peers']
)

validacion_categorias.round(2)
```

Out[38]:

categoria_cons	n_reseñas	rating_medio	pct_recomienda	peso_en_cons_pct	gap_rating_vs_total_remax	gap_recomendacion_vs_total_remax	n_empresas_peers	ra
Cultura, liderazgo y equipo	69	3.20	30.43	6.9	-0.89	-11.77	5	
Carrera y desarrollo	24	3.79	45.83	2.4	-0.30	3.63	5	
Ventas, clientes y captación	33	3.82	42.42	3.3	-0.28	0.22	5	
Compensación, comisiones y costes	272	3.89	36.40	27.2	-0.21	-5.80	5	
Tecnología, herramientas y procesos	16	3.94	37.50	1.6	-0.16	-4.70	5	
Modelo de negocio y mercado	50	4.10	50.00	5.0	0.00	7.80	5	
Oficinas y entorno físico	21	4.14	47.62	2.1	0.05	5.42	5	
Formación, onboarding y soporte	61	4.20	37.70	6.1	0.10	-4.50	5	
Flexibilidad, conciliación y carga de trabajo	108	4.31	47.22	10.8	0.21	5.02	5	
Estructura y organización	13	4.31	61.54	1.3	0.21	19.34	5	

In [39]:
```
# Guardamos los resultados de la validación de categorías y su impacto en rating y recomendación

validacion_categorias.to_csv(
    OUTPUTS_DIR / 'validacion_categorias_rating_recomendacion.csv',
)

print(
    OUTPUTS_DIR /
    'validacion_categorias_rating_recomendacion.csv'
)
```

../outputs/validacion_categorias_rating_recomendacion.csv

In [40]:

```
datos_impacto_rating = (
    impacto_remax['gap_rating_vs_total_remax']
    .sort_values()
)

colores = [
    '#E76F51' if valor < 0 else '#2A9D8F'
    for valor in datos_impacto_rating
]

fig, ax = plt.subplots(figsize=(10, 6))

barras = ax.barh(
    datos_impacto_rating.index,
    datos_impacto_rating.values,
    color=colores,
)

ax.axvline(0, color='black', linewidth=1)

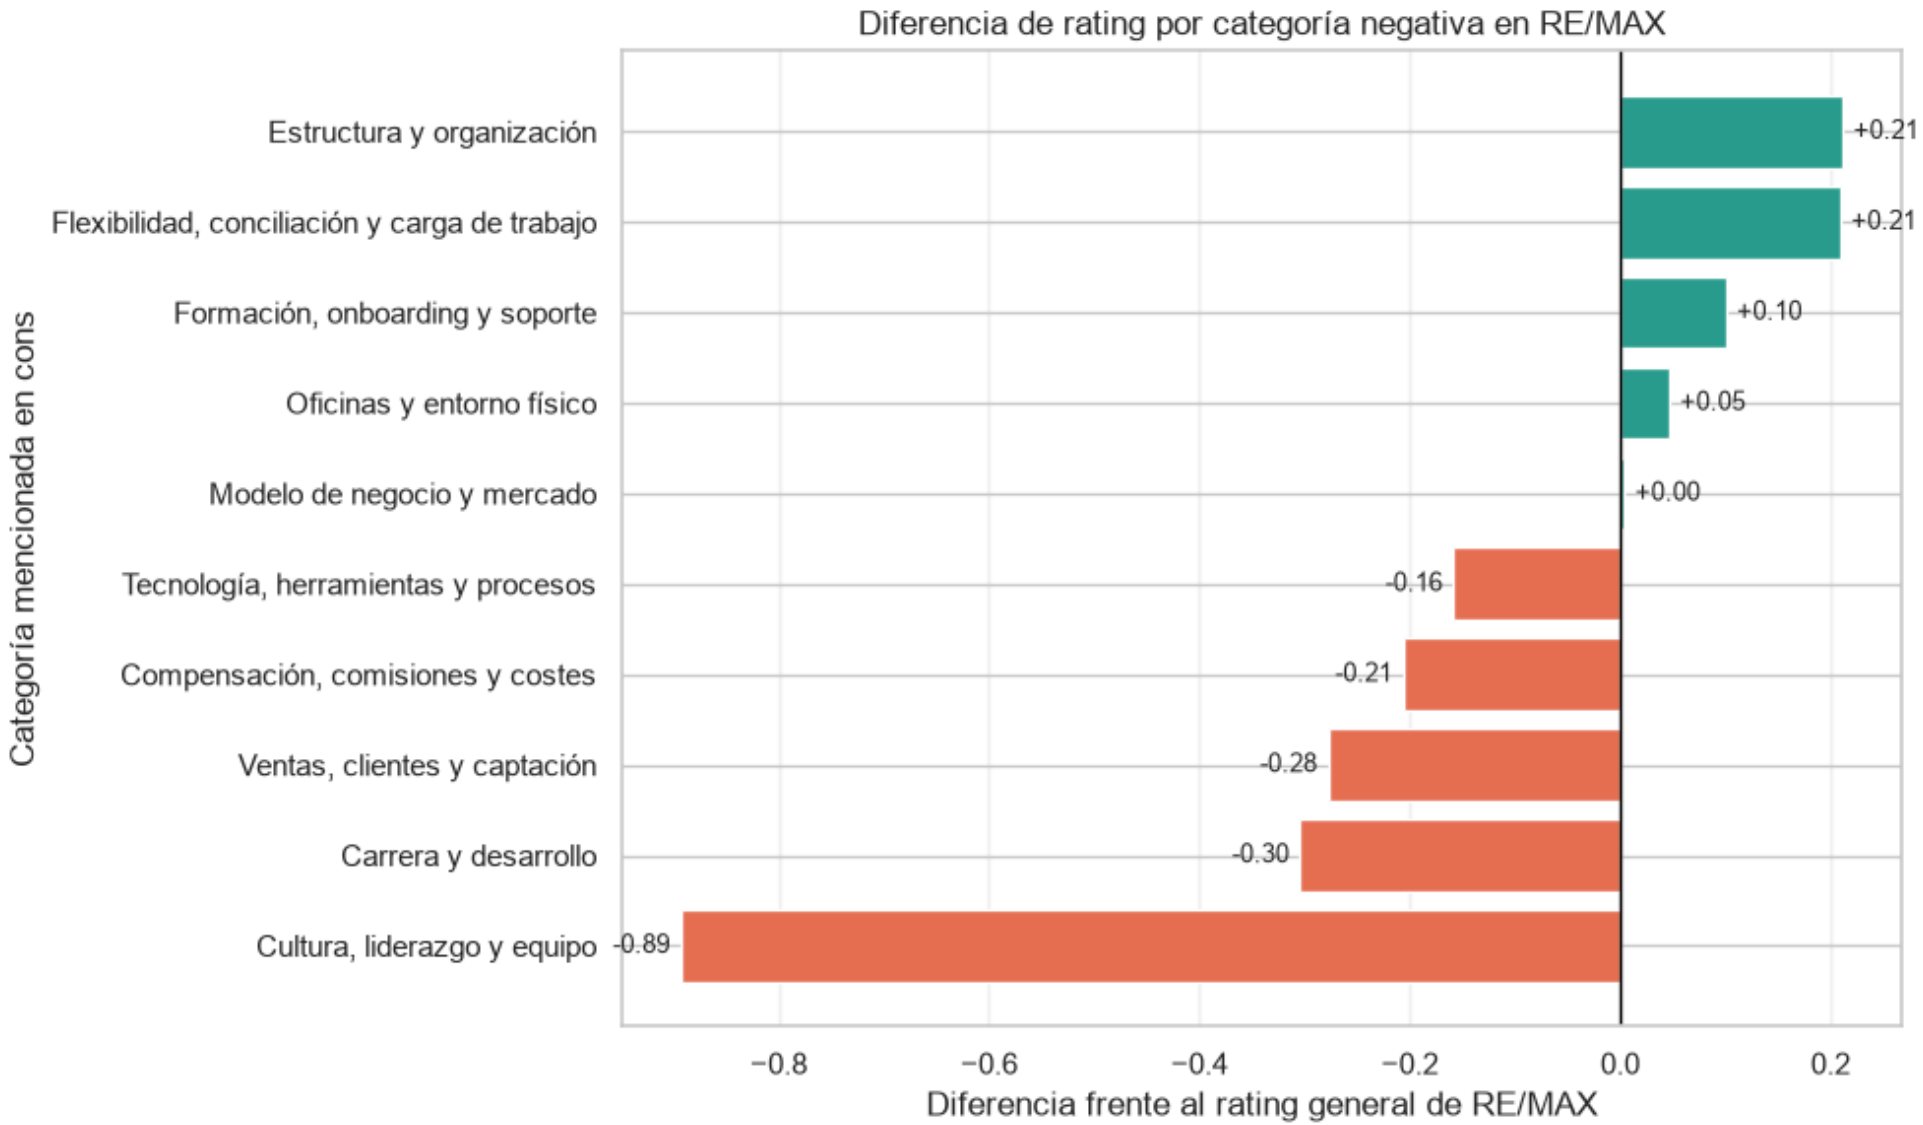
ax.set(
    title='Diferencia de rating por categoría negativa en RE/MAX',
    xlabel='Diferencia frente al rating general de RE/MAX',
    ylabel='Categoría mencionada en cons',
)

ax.bar_label(
    barras,
    labels=[
        f'{valor:+.2f}'
        for valor in datos_impacto_rating.values
    ],
    padding=4,
    fontsize=9,
)

ax.grid(axis='x', alpha=0.25)
plt.tight_layout()

fig.savefig(
    IMAGES_DIR / 'impacto_categorias_cons_rating_remax.png',
    dpi=160,
    bbox_inches='tight',
)

plt.show()
```



Validación mediante rating y recomendación

`Compensación, comisiones y costes` queda confirmada como la principal debilidad de RE/MAX. Es la categoría con mayor peso en los cons, presenta un balance muy inferior al de los peers y sus reseñas tienen un rating y una recomendación inferiores a los valores generales de

la empresa. La menor recomendación frente a los peers para esta misma categoría refuerza su relevancia competitiva.

Las quejas sobre `Cultura, liderazgo y equipo` tienen el mayor impacto sobre la experiencia individual: su rating medio es 3,20 y solo el 30,4% recomienda la empresa. Sin embargo, RE/MAX presenta un balance más favorable que los peers en esta categoría. Por tanto, constituye un problema grave cuando ocurre, pero no una debilidad diferencial frente al mercado.

Las categorías `Modelo de negocio y mercado` y `Oficinas y entorno físico` no presentan un rating ni una recomendación inferiores al promedio de RE/MAX, por lo que no quedan confirmadas como prioridades. `Tecnología, herramientas y procesos` muestra una menor recomendación, pero solo contiene 16 reseñas y debe interpretarse con cautela.

`Flexibilidad, conciliación y carga de trabajo` se confirma como una fortaleza: incluso las reseñas cuyos cons se asignan a esta categoría presentan un rating y una recomendación superiores a la media de RE/MAX y a los resultados equivalentes de los peers.

Extra: evolución temporal de las principales categorías

El enunciado propone como ampliación analizar si los temas principales cambian con el tiempo. Para evitar que el distinto número de reseñas por empresa distorsione el benchmark, se calcula primero el porcentaje anual dentro de cada empresa y después la media simple de los peers.

El denominador es el total de reseñas de cada empresa y año, incluidos los textos sin asignar. Se muestran `Compensación, comisiones y costes`, `Cultura, liderazgo y equipo` y `Formación, onboarding y soporte`, por ser categorías especialmente relevantes para las decisiones de RR. HH. Los años 2018 y 2023 son incompletos y deben interpretarse con cautela.

In [41]:
```
# Evolución anual de categorías relevantes en los cons: RE/MAX frente a peers

CATEGORIAS_EVOLUCION = [
    COMPENSACION,
    CULTURA,
    FORMACION,
]

anios_analisis = sorted(df['anio'].dropna().astype(int).unique())

indice_temporal = pd.MultiIndex.from_product(
    [FIRMS, anios_analisis, CATEGORIAS_EVOLUCION],
    names=['firm', 'anio', 'categoria_cons'],
)

totales_empresa_anio = (
    df.groupby(['firm', 'anio'], observed=True)
      .size()
```

```
      .rename('n_total')
)

conteos_categoria_anio = (
    df[df['categoria_cons'].isin(CATEGORIAS_EVOLUCION)]
      .groupby(['firm', 'anio', 'categoria_cons'], observed=True)
      .size()
      .reindex(indice_temporal, fill_value=0)
      .rename('n_categoria')
      .reset_index()
)

evolucion_categorias_empresa = (
    conteos_categoria_anio
    .merge(
        totales_empresa_anio.reset_index(),
        on=['firm', 'anio'],
        how='left',
        validate='many_to_one',
    )
)

evolucion_categorias_empresa['pct_cons'] = (
    evolucion_categorias_empresa['n_categoria']
    / evolucion_categorias_empresa['n_total']
    * 100
)

evolucion_remax = (
    evolucion_categorias_empresa[
        evolucion_categorias_empresa['firm'].eq(TARGET)
    ][['anio', 'categoria_cons', 'n_total', 'pct_cons']]
    .rename(columns={
        'n_total': 'n_reseñas_remax',
        'pct_cons': 'RE/MAX (%)',
    })
)

evolucion_peers = (
    evolucion_categorias_empresa[
        evolucion_categorias_empresa['firm'].isin(PEERS)
    ]
    .groupby(['anio', 'categoria_cons'], observed=True)['pct_cons']
    .mean()
    .rename('Media peers (%)')
    .reset_index()
)

evolucion_temporal_categorias = (
    evolucion_remax
```

```
    .merge(
        evolucion_peers,
        on=['anio', 'categoria_cons'],
        how='left',
        validate='one_to_one',
    )
)

evolucion_temporal_categorias['Gap RE/MAX vs. peers'] = (
    evolucion_temporal_categorias['RE/MAX (%)']
    - evolucion_temporal_categorias['Media peers (%)']
)

tabla_temporal_categorias = (
    evolucion_temporal_categorias
    .pivot(
        index='anio',
        columns='categoria_cons',
        values=['RE/MAX (%)', 'Media peers (%)', 'Gap RE/MAX vs. peers'],
    )
    .round(2)
)

display(tabla_temporal_categorias)

evolucion_temporal_categorias.to_csv(
    OUTPUTS_DIR / 'evolucion_temporal_categorias_remax_vs_peers.csv',
    index=False,
    encoding='utf-8-sig',
)
```

	RE/MAX (%)			Media peers (%)			Gap RE/MAX vs. peers		
categoria_cons	Compensación, comisiones y costes	Cultura, liderazgo y equipo	Formación, onboarding y soporte	Compensación, comisiones y costes	Cultura, liderazgo y equipo	Formación, onboarding y soporte	Compensación, comisiones y costes	Cultura, liderazgo y equipo	Formación, onboarding y soporte
anio									
2018	24.44	8.89	13.33	18.97	13.57	4.74	5.48	-4.69	8.59
2019	22.22	9.09	9.09	19.26	19.87	4.06	2.97	-10.78	5.03
2020	31.13	7.95	7.95	16.41	18.56	5.42	14.72	-10.61	2.52
2021	26.25	4.98	4.65	18.93	12.90	4.54	7.32	-7.92	0.11
2022	27.52	7.65	5.50	18.46	16.28	4.37	9.06	-8.63	1.14
2023	29.87	5.19	2.60	24.66	16.82	3.94	5.21	-11.62	-1.34

In [42]:

```python
# Visualización de la evolución temporal de las categorías seleccionadas

colores_temporales = {
    COMPENSACION: '#C1121F',
    CULTURA: '#2A9D8F',
    FORMACION: '#E9A23B',
}

fig, axes = plt.subplots(
    1,
    len(CATEGORIAS_EVOLUCION),
    figsize=(16, 4.5),
    sharex=True,
)

for ax, categoria in zip(axes, CATEGORIAS_EVOLUCION):
    datos_categoria = (
        evolucion_temporal_categorias[
            evolucion_temporal_categorias['categoria_cons'].eq(categoria)
        ]
        .sort_values('anio')
    )

    ax.plot(
        datos_categoria['anio'],
        datos_categoria['RE/MAX (%)'],
        marker='o',
        linewidth=2.3,
        color=colores_temporales[categoria],
        label='RE/MAX',
    )
    ax.plot(
        datos_categoria['anio'],
        datos_categoria['Media peers (%)'],
        marker='o',
        linewidth=2,
        linestyle='--',
        color='#457B9D',
        label='Media peers',
    )

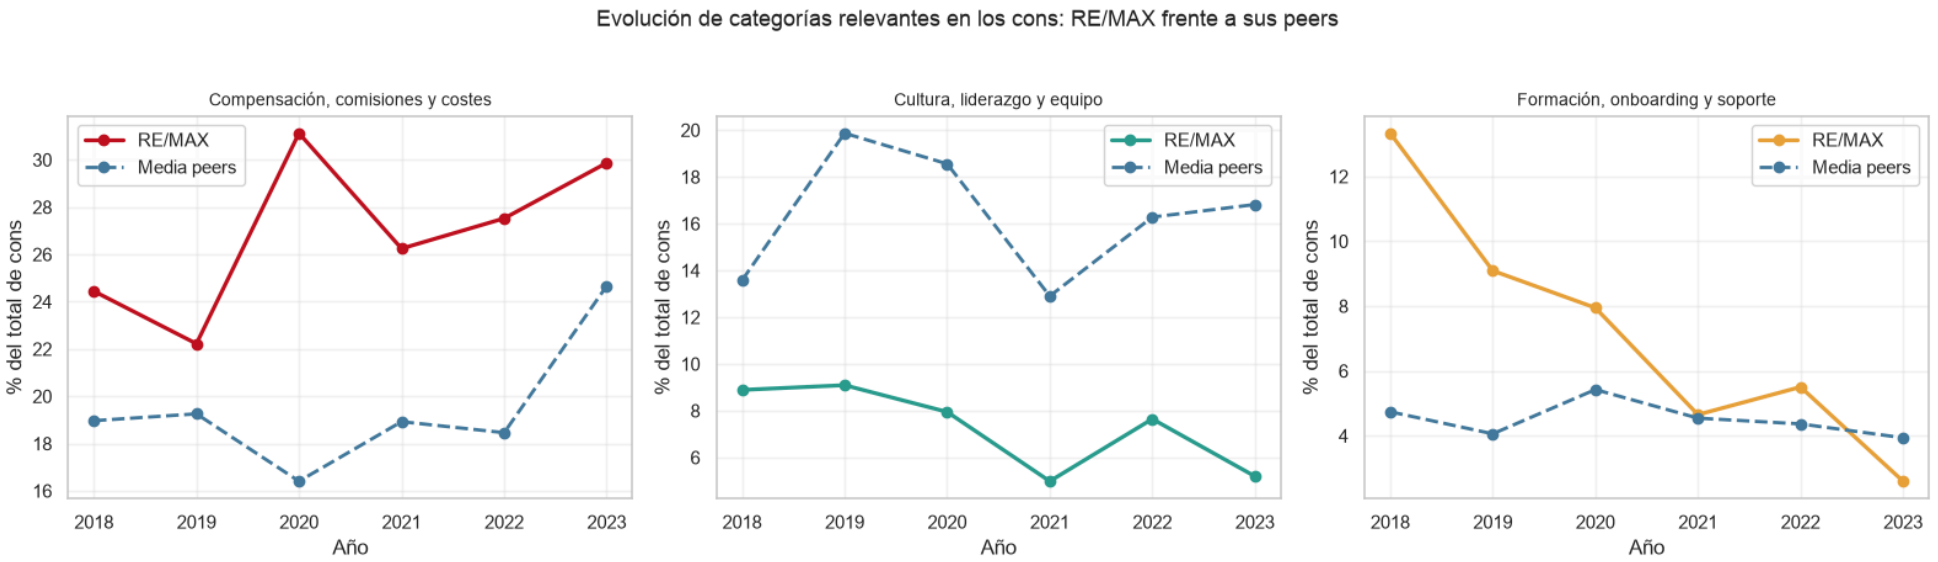
    ax.set_title(categoria, fontsize=10)
    ax.set_xlabel('Año')
    ax.set_ylabel('% del total de cons')
    ax.grid(alpha=0.25)
    ax.legend()

fig.suptitle(
    'Evolución de categorías relevantes en los cons: RE/MAX frente a sus peers',
```

```
    fontsize=13,
    y=1.03,
)
plt.tight_layout()

fig.savefig(
    IMAGES_DIR / 'evolucion_temporal_categorias_remax_vs_peers.png',
    dpi=160,
    bbox_inches='tight',
)

plt.show()
```



Lectura del análisis temporal

`Compensación, comisiones y costes` se mantiene por encima de la media de los peers en todos los años observados. La brecha alcanza su máximo en 2020 (+14,72 puntos porcentuales) y continúa siendo desfavorable en 2023 (+5,21 puntos). Por tanto, no parece una incidencia aislada de un único periodo, sino una fricción persistente del modelo económico.

`Cultura, liderazgo y equipo` presenta el patrón contrario: RE/MAX recibe menos menciones negativas que los peers durante toda la serie, con gaps favorables comprendidos entre 4,69 y 11,62 puntos. Esto refuerza su consideración como fortaleza relativa, aunque el análisis por recomendación mostrará que puede convertirse en un riesgo intenso cuando se produce una experiencia negativa.

La evolución de `Formación, onboarding y soporte` es especialmente relevante. Su peso en los cons de RE/MAX desciende desde el 13,33% en 2018 hasta el 2,60% en 2023, mientras que la brecha frente a los peers pasa de +8,59 a -1,34 puntos. Este resultado es compatible con una mejora de los procesos de incorporación y apoya la hipótesis de que algunos antiguos empleados pudieron experimentar procedimientos anteriores.

Los datos de 2018 y 2023 solo contienen 45 y 77 reseñas de RE/MAX, respectivamente, y ambos años están incompletos. Además, la fecha corresponde a la publicación de la reseña, no necesariamente al momento exacto de la experiencia. Las tendencias deben interpretarse como evidencia descriptiva y no causal.

---

5. Empleados actuales frente a antiguos

Los cons de los antiguos empleados se utilizan como aproximación a posibles motivos de salida. La comparación se centra en la distribución de temas, no en el sentimiento general, porque los antiguos empleados puntúan sistemáticamente peor en todas las empresas.

Se realizan dos comparaciones:

1. Antiguos frente a actuales dentro de RE/MAX.
2. Antiguos de RE/MAX frente a antiguos de los peers.

In [43]:
```
# Distribución dentro de RE/MAX

porcentaje_cons_situacion_remax = (
    pd.crosstab(
        df_remax['situacion'],
        df_remax['categoria_cons'],
        normalize='index',
    ) * 100
)

porcentaje_cons_situacion_remax = (
    porcentaje_cons_situacion_remax
    .reindex(
        index=['Actual', 'Antiguo'],
        columns=ORDEN_CATEGORIAS,
        fill_value=0,
    )
)
```

```
porcentaje_cons_situacion_remax.round(1)
```

Out[43]:

categoria_cons	Cultura, liderazgo y equipo	Flexibilidad, conciliación y carga de trabajo	Compensación, comisiones y costes	Formación, onboarding y soporte	Carrera y desarrollo	Marca y reputación	Ventas, clientes y captación	Tecnología, herramientas y procesos	Oficinas y entorno físico	Modelo de negocio y mercado	Estructura y organización	Valoración general sin detalle	in
situacion													
Actual	4.9	11.4	26.8	6.5	1.8	0	3.2	1.9	2.8	5.6	1.2	0	
Antiguo	9.5	10.0	27.8	5.6	3.2	0	3.5	1.2	1.2	4.2	1.4	0	

In [44]:

```
# Antiguos de RE/MAX frente a los peers

df_antiguos = df[df['situacion'].eq('Antiguo')].copy()

porcentaje_cons_antiguos_empresa = (
    pd.crosstab(
        df_antiguos['firm'],
        df_antiguos['categoria_cons'],
        normalize='index',
    ) * 100
)

porcentaje_cons_antiguos_empresa = (
    porcentaje_cons_antiguos_empresa
    .reindex(
        index=FIRMS,
        columns=ORDEN_CATEGORIAS,
        fill_value=0,
    )
)

media_antiguos_peers = (
    porcentaje_cons_antiguos_empresa
    .loc[PEERS]
    .mean()
)

analisis_antiguos = pd.DataFrame({
    'Actuales RE/MAX (%)':
        porcentaje_cons_situacion_remax.loc['Actual'],
    'Antiguos RE/MAX (%)':
        porcentaje_cons_situacion_remax.loc['Antiguo'],
    'Antiguos peers (%)':
        media_antiguos_peers,
```

```
})

analisis_antiguos['Gap antiguos vs. actuales'] = (
    analisis_antiguos['Antiguos RE/MAX (%)']
    - analisis_antiguos['Actuales RE/MAX (%)']
)

analisis_antiguos['Gap antiguos RE/MAX vs. peers'] = (
    analisis_antiguos['Antiguos RE/MAX (%)']
    - analisis_antiguos['Antiguos peers (%)']
)

analisis_antiguos_negocio = (
    analisis_antiguos
    .loc[CATEGORIAS_NEGOCIO]
    .sort_values(
        'Gap antiguos RE/MAX vs. peers',
        ascending=False,
    )
)

analisis_antiguos_negocio.round(2)
```

Out[44]:

categoria_cons	Actuales RE/MAX (%)	Antiguos RE/MAX (%)	Antiguos peers (%)	Gap antiguos vs. actuales	Gap antiguos RE/MAX vs. peers
Compensación, comisiones y costes	26.76	27.78	17.62	1.02	10.16
Modelo de negocio y mercado	5.63	4.17	3.46	-1.47	0.71
Flexibilidad, conciliación y carga de trabajo	11.44	9.95	9.55	-1.49	0.40
Carrera y desarrollo	1.76	3.24	2.97	1.48	0.27
Formación, onboarding y soporte	6.51	5.56	5.31	-0.96	0.25
Marca y reputación	0.00	0.00	0.00	0.00	0.00
Estructura y organización	1.23	1.39	1.55	0.16	-0.16
Oficinas y entorno físico	2.82	1.16	1.38	-1.66	-0.22
Tecnología, herramientas y procesos	1.94	1.16	1.96	-0.78	-0.80
Ventas, clientes y captación	3.17	3.47	4.49	0.30	-1.02
Cultura, liderazgo y equipo	4.93	9.49	21.68	4.56	-12.19

In [45]:
```
# Guardamos el resultado

analisis_antiguos_negocio.to_csv(
    OUTPUTS_DIR / 'cons_antiguos_remax_vs_peers.csv',
)

print(
    OUTPUTS_DIR /
    'cons_antiguos_remax_vs_peers.csv'
)
```

```
../outputs/cons_antiguos_remax_vs_peers.csv
```

Posibles motivos de salida y cambio del marco de comparación

Los antiguos empleados y asociados de RE/MAX otorgan un rating medio de 3,75, frente a 4,36 entre quienes continúan en la compañía. Esta diferencia no implica necesariamente que la experiencia empeore únicamente como consecuencia de abandonar RE/MAX. También puede reflejar un cambio en el marco de referencia desde el que se evalúa la empresa.

Después de salir, un profesional puede conocer otros modelos de trabajo, estructuras de comisiones, sistemas de soporte y procedimientos comerciales. También puede intentar establecerse de forma independiente con una marca propia o incorporarse a una agencia más pequeña. Estas experiencias amplían sus puntos de comparación y pueden modificar retrospectivamente su valoración de RE/MAX en ambos sentidos.

Por un lado, trabajar fuera de una gran red puede hacer más visibles las ventajas de RE/MAX, como el reconocimiento de marca, el acceso a formación, las herramientas comerciales y el soporte de una estructura consolidada. Esto podría contribuir a que RE/MAX conserve un rating relativamente elevado entre sus antiguos empleados: 3,75, el valor más alto del grupo analizado, y una brecha entre actuales y antiguos menor que la media de los peers.

Por otro lado, conocer modelos con menores costes, mayor autonomía o sistemas diferentes de reparto puede hacer que las comisiones, cuotas y gastos asociados a RE/MAX se perciban de forma más crítica. Esta interpretación es coherente con el análisis temático: `Compensación, comisiones y costes` representa el 27,8% de los cons de antiguos empleados de RE/MAX, aproximadamente diez puntos porcentuales más que entre los antiguos empleados de los peers.

Las menciones a `Cultura, liderazgo y equipo` también aumentan entre los antiguos frente a los actuales. Esto sugiere que determinadas experiencias con la dirección, el equipo o una oficina concreta pueden intervenir en algunas salidas. Sin embargo, esta categoría tiene mucho menos peso entre los antiguos de RE/MAX que entre los antiguos de los peers, por lo que no constituye una debilidad competitiva general.

`Carrera y desarrollo` aumenta moderadamente entre antiguos y actuales, pero su peso es reducido y apenas difiere del observado en los peers. Se considera una señal secundaria que conviene monitorizar.

También debe considerarse la evolución de la propia empresa. Los empleados actuales experimentan las políticas, herramientas, sistemas de soporte y estilos de dirección vigentes en el momento más reciente. En cambio, parte de los antiguos empleados puede estar valorando procesos que RE/MAX ya ha modificado o sustituido.

Si la compañía ha mejorado su formación, tecnología, comunicación o soporte al agente, la menor valoración de los antiguos podría reflejar una etapa anterior y no representar completamente la experiencia actual. En ese caso, comparar ambos grupos sin considerar el momento temporal podría exagerar la magnitud de los problemas vigentes.

También podría ocurrir lo contrario: si determinados procesos se han deteriorado, los antiguos empleados podrían conservar una percepción más favorable de una etapa previa. Por tanto, la situación laboral puede estar relacionada con la antigüedad de la experiencia y con la evolución organizativa de RE/MAX.

La variable `date_review` indica cuándo se publicó la reseña, pero no proporciona las fechas exactas de entrada y salida ni permite identificar qué versión de los procesos experimentó cada persona. En consecuencia, no es posible separar completamente el efecto de abandonar la empresa del efecto de pertenecer a una etapa organizativa diferente.

En conjunto, las diferencias entre actuales y antiguos pueden responder a tres mecanismos:

- un sesgo de selección entre quienes permanecen y quienes salen,
- una reevaluación posterior al conocer otras alternativas profesionales
- y la evolución de RE/MAX a lo largo del tiempo.

Glassdoor no sigue a las mismas personas antes y después de su salida ni identifica con precisión los procesos que experimentaron. Por ello, estas explicaciones deben interpretarse como hipótesis plausibles para RRHH y no como relaciones causales demostradas.

In [46]:
```
# Comprobación temporal complementaria
rating_anual_situacion_remax = (
    df_remax
    .groupby(['anio', 'situacion'], observed=True)
    .agg(
        n_reseñas=('overall_rating', 'size'),
        rating_medio=('overall_rating', 'mean'),
    )
    .reset_index()
)

rating_anual_situacion_remax
```

Out[46]:

	anio	situacion	n_reseñas	rating_medio
0	2018	Actual	24	4.083333
1	2018	Antiguo	21	3.619048
2	2019	Actual	53	4.150943
3	2019	Antiguo	46	3.891304
4	2020	Actual	86	4.406977
5	2020	Antiguo	65	3.584615
6	2021	Actual	168	4.351190
7	2021	Antiguo	133	3.684211
8	2022	Actual	198	4.398990
9	2022	Antiguo	129	3.930233
10	2023	Actual	39	4.487179
11	2023	Antiguo	38	3.605263

In [47]:

```
brecha_anual_situacion = (
    rating_anual_situacion_remax
    .pivot(
        index='anio',
        columns='situacion',
        values='rating_medio',
    )
    .reindex(columns=['Actual', 'Antiguo'])
)

brecha_anual_situacion['Brecha actual - antiguo'] = (
    brecha_anual_situacion['Actual']
    - brecha_anual_situacion['Antiguo']
)

brecha_anual_situacion.round(2)
```

Out[47]:

situacion	Actual	Antiguo	Brecha actual - antiguo
anio			
2018	4.08	3.62	0.46
2019	4.15	3.89	0.26
2020	4.41	3.58	0.82
2021	4.35	3.68	0.67
2022	4.40	3.93	0.47
2023	4.49	3.61	0.88

Esta comprobación controla parcialmente el año de publicación, pero no resuelve por completo el problema: una reseña publicada en 2022 por un antiguo empleado podría describir procesos vividos bastante antes. Esa limitación debe permanecer explícita.

Extra: análisis por antigüedad

La antigüedad puede revelar si las fricciones aparecen principalmente durante la incorporación o después de conocer mejor el modelo de negocio. Se analizan por separado los intervalos declarados en Glassdoor. La categoría `n/d` se conserva en la tabla para mantener la trazabilidad, pero se excluye del gráfico porque no representa un tramo comparable.

Los porcentajes temáticos se calculan sobre todas las reseñas de RE/MAX de cada tramo, incluidos los textos sin asignar. Los resultados de los grupos pequeños deben interpretarse con cautela.

In [48]:

```
# Rating, recomendación y temas relevantes de RE/MAX por antigüedad

ORDEN_ANTIGUEDAD = [
    'less than 1y',
    'more than 1y',
    'more than 3y',
    'more than 5y',
    'more than 8y',
    'more than 10y',
    'n/d',
]

ETIQUETAS_ANTIGUEDAD = {
    'less than 1y': 'Menos de 1 año',
    'more than 1y': 'Más de 1 año',
    'more than 3y': 'Más de 3 años',
```

```
    'more than 5y': 'Más de 5 años',
    'more than 8y': 'Más de 8 años',
    'more than 10y': 'Más de 10 años',
    'n/d': 'No disponible',
}

resumen_antiguedad_remax = (
    df_remax.groupby('antiguedad', observed=True)
    .agg(
        n_reseñas=('firm', 'size'),
        rating_medio=('overall_rating', 'mean'),
        pct_recomienda=(
            'recomienda',
            lambda s: s.eq('Sí').mean() * 100,
        ),
    )
    .reindex(ORDEN_ANTIGUEDAD)
)

for categoria, nombre_columna in {
    COMPENSACION: 'pct_compensacion_cons',
    CULTURA: 'pct_cultura_cons',
    FORMACION: 'pct_formacion_cons',
}.items():
    resumen_antiguedad_remax[nombre_columna] = (
        df_remax.assign(
            menciona_categoria=df_remax['categoria_cons'].eq(categoria)
        )
        .groupby('antiguedad', observed=True)['menciona_categoria']
        .mean()
        .reindex(ORDEN_ANTIGUEDAD)
        * 100
    )

resumen_antiguedad_remax = resumen_antiguedad_remax.rename(
    index=ETIQUETAS_ANTIGUEDAD
)

display(resumen_antiguedad_remax.round(2))

resumen_antiguedad_remax.to_csv(
    OUTPUTS_DIR / 'analisis_antiguedad_remax.csv',
    encoding='utf-8-sig',
)
```

antiguedad	n_reseñas	rating_medio	pct_recomienda	pct_compensacion_cons	pct_cultura_cons	pct_formacion_cons
Menos de 1 año	121	3.64	45.45	19.83	11.57	9.09
Más de 1 año	164	4.07	53.05	24.39	8.54	7.32
Más de 3 años	117	4.15	62.39	32.48	5.13	7.69
Más de 5 años	57	3.79	52.63	29.82	10.53	7.02
Más de 8 años	35	4.00	62.86	37.14	8.57	0.00
Más de 10 años	34	4.59	70.59	23.53	8.82	2.94
No disponible	472	4.22	27.75	27.97	4.87	5.08

In [49]:
```
# Visualización del rating y la recomendación por antigüedad

antiguedad_grafico = (
    resumen_antiguedad_remax
    .drop(index='No disponible')
    .reset_index(names='antiguedad')
)

fig, axes = plt.subplots(1, 2, figsize=(14, 5))

sns.barplot(
    data=antiguedad_grafico,
    x='antiguedad',
    y='rating_medio',
    color='#2A9D8F',
    ax=axes[0],
)
axes[0].set(
    title='Rating medio de RE/MAX por antigüedad',
    xlabel='Antigüedad declarada',
    ylabel='Rating medio',
    ylim=(0, 5),
)

sns.barplot(
    data=antiguedad_grafico,
    x='antiguedad',
    y='pct_recomienda',
    color='#E76F51',
    ax=axes[1],
)
axes[1].set(
```

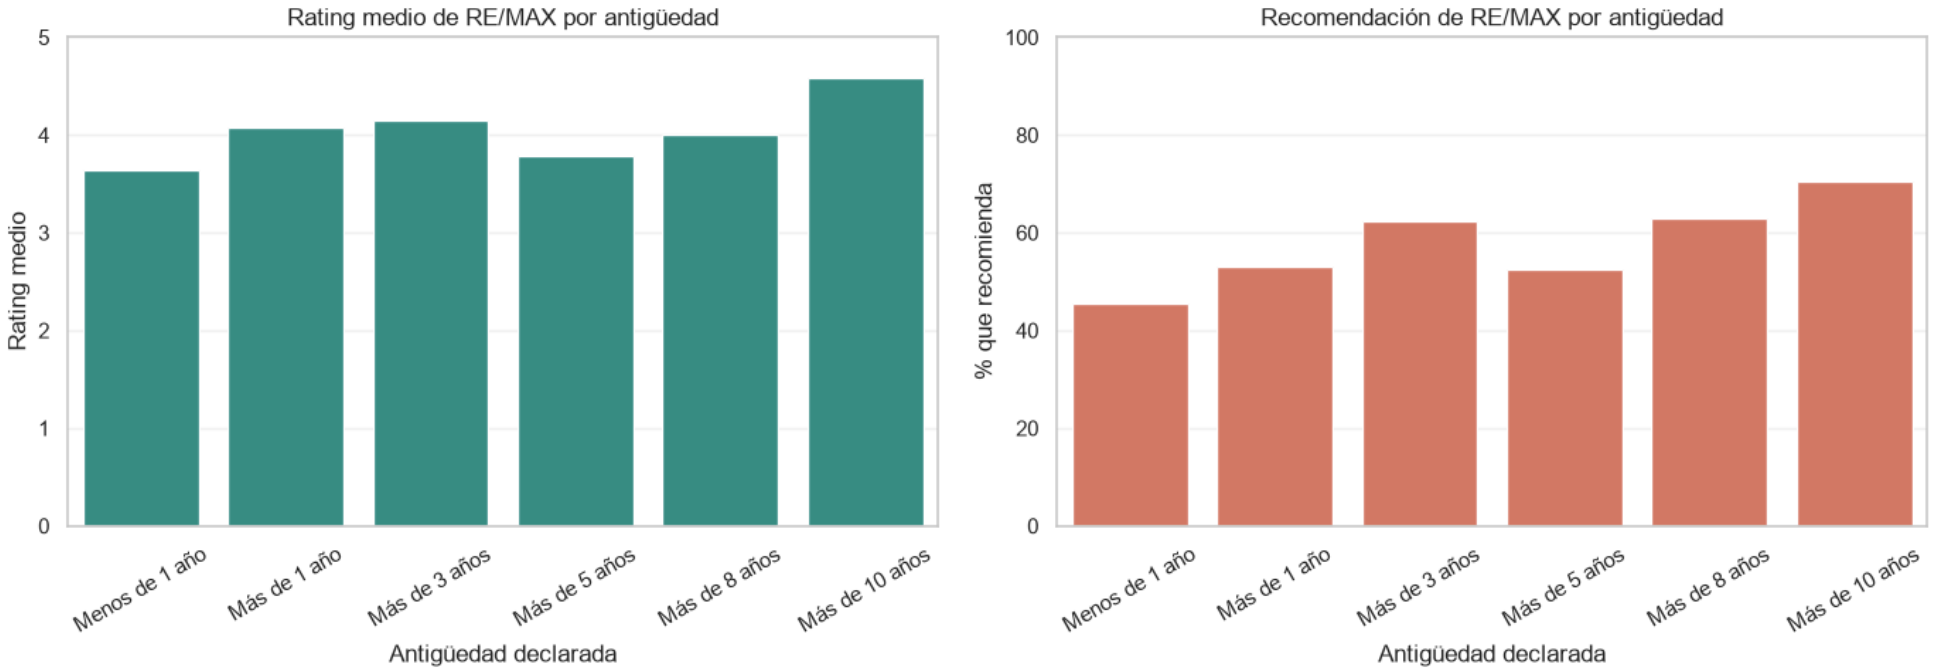
```
    title='Recomendación de RE/MAX por antigüedad',
    xlabel='Antigüedad declarada',
    ylabel='% que recomienda',
    ylim=(0, 100),
)

for ax in axes:
    ax.tick_params(axis='x', rotation=30)
    ax.grid(axis='y', alpha=0.25)

plt.tight_layout()

fig.savefig(
    IMAGES_DIR / 'antiguedad_rating_recomendacion_remax.png',
    dpi=160,
    bbox_inches='tight',
)

plt.show()
```



Lectura por antigüedad

El tramo de menos de un año presenta el rating más bajo entre los grupos con antigüedad declarada (3,64) y una recomendación del 45,45%. También registra más menciones a cultura y liderazgo (11,57%) y formación/onboarding (9,09%) que la mayoría de los tramos posteriores. Esto refuerza la conveniencia de acompañar especialmente los primeros meses y comprobar que las expectativas iniciales coinciden con la experiencia real.

Las menciones a compensación aumentan conforme se conoce mejor el modelo: pasan del 19,83% durante el primer año al 32,48% por encima de tres años y al 37,14% por encima de ocho. El patrón no es completamente lineal, pero sugiere que comisiones, cuotas y costes pueden hacerse más visibles con la permanencia y la experiencia acumulada.

Los grupos de más de ocho y diez años contienen solo 35 y 34 reseñas, respectivamente, por lo que sus valores no deben generalizarse. La categoría `No disponible` reúne 472 reseñas y se mantiene separada porque mezcla perfiles cuya antigüedad no puede conocerse. Los intervalos son etiquetas declaradas y no representan el seguimiento longitudinal de las mismas personas.

Extra: segmentación específica por recomendación

La variable de recomendación permite comparar qué temas aparecen entre promotores, respuestas neutrales y detractores. El objetivo no es volver a validar el rating, sino detectar qué categorías negativas distinguen especialmente a quienes no recomendarían RE/MAX.

Se seleccionan para la visualización las cinco categorías de negocio con mayor presencia global en los cons de RE/MAX. Los porcentajes mantienen como denominador todas las reseñas de cada segmento de recomendación.

In [50]:
```
# Distribución de categorías negativas según la recomendación de RE/MAX

ORDEN_RECOMENDACION = ['Sí', 'Neutral', 'No']

resumen_recomendacion_remax = (
    df_remax.groupby('recomienda', observed=True)
    .agg(
        n_reseñas=('firm', 'size'),
        rating_medio=('overall_rating', 'mean'),
    )
    .reindex(ORDEN_RECOMENDACION)
)

categorias_por_recomendacion = (
    pd.crosstab(
        df_remax['recomienda'],
        df_remax['categoria_cons'],
        normalize='index',
    )
```

```
    .reindex(
        index=ORDEN_RECOMENDACION,
        columns=ORDEN_CATEGORIAS,
        fill_value=0,
    )
    * 100
)

segmentacion_recomendacion_remax = (
    resumen_recomendacion_remax
    .join(categorias_por_recomendacion[CATEGORIAS_NEGOCIO])
)

categorias_principales_recomendacion = (
    porcentaje_cons_exacto
    .loc[TARGET, CATEGORIAS_NEGOCIO]
    .nlargest(5)
    .index
    .tolist()
)

print('Resumen por recomendación:')
display(resumen_recomendacion_remax.round(2))

print('Categorías principales en cons por recomendación (%):')
display(
    categorias_por_recomendacion[
        categorias_principales_recomendacion
    ].round(2)
)

segmentacion_recomendacion_remax.to_csv(
    OUTPUTS_DIR / 'segmentacion_recomendacion_remax.csv',
    encoding='utf-8-sig',
)
```

```
Resumen por recomendación:
```

recomienda	n_reseñas	rating_medio
Sí	422	4.59
Neutral	443	4.12
No	135	2.47

```
Categorías principales en cons por recomendación (%):
```

categoria_cons recomienda	Compensación, comisiones y costes	Flexibilidad, conciliación y carga de trabajo	Cultura, liderazgo y equipo	Formación, onboarding y soporte	Modelo de negocio y mercado
Sí	23.46	12.09	4.98	5.45	5.92
Neutral	30.02	10.38	4.29	6.55	3.84
No	29.63	8.15	21.48	6.67	5.93

In [51]:
```
# Mapa de calor de las categorías negativas por recomendación

datos_heatmap_recomendacion = categorias_por_recomendacion[
    categorias_principales_recomendacion
]

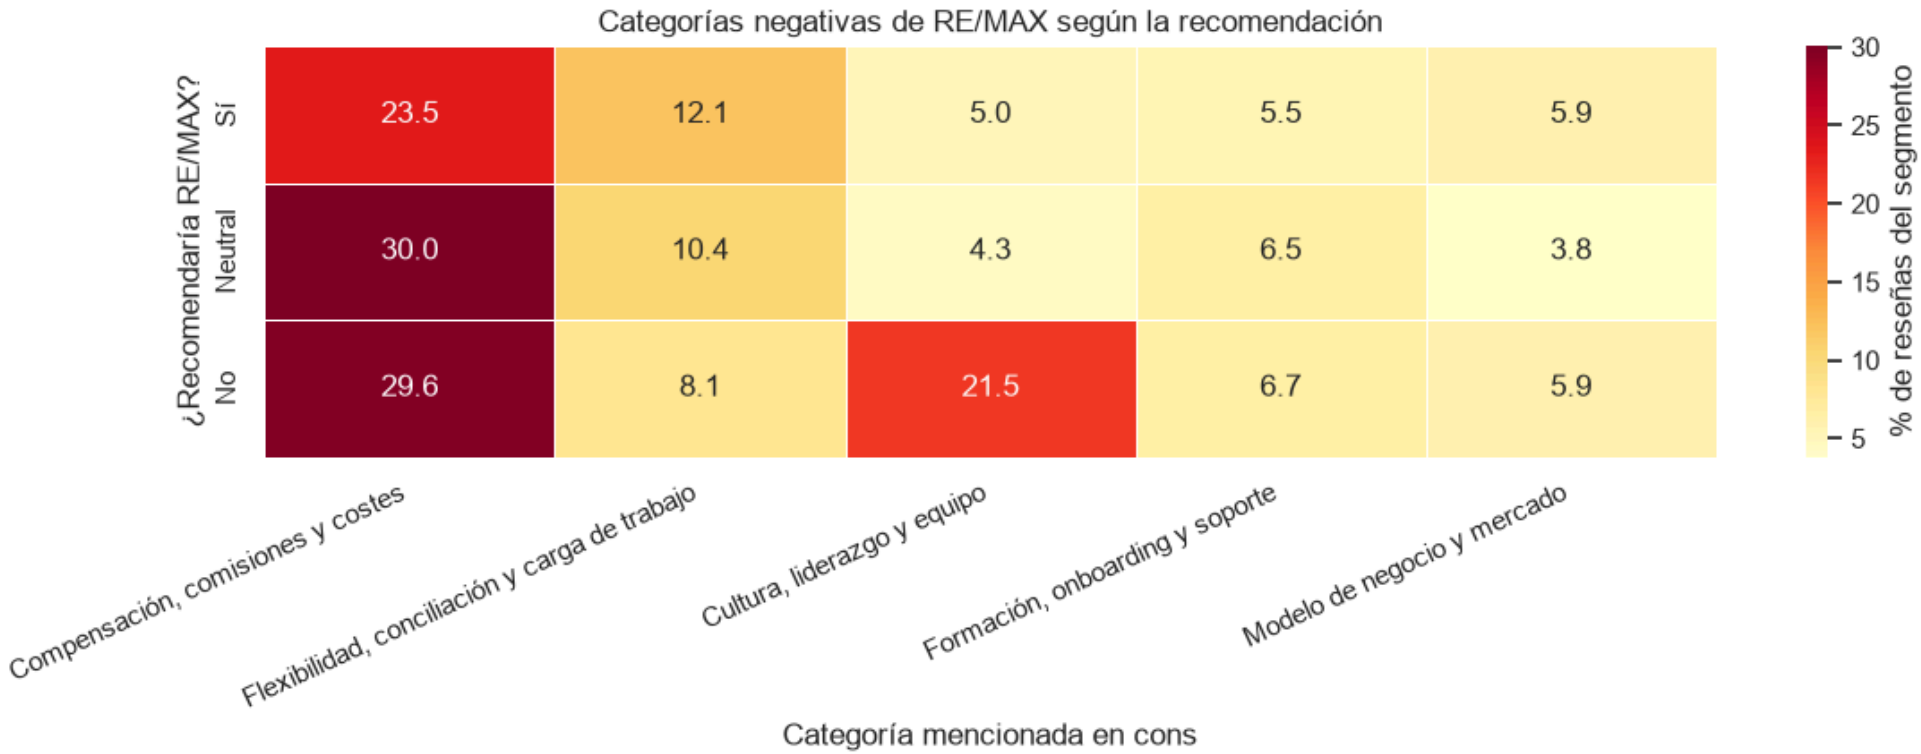
fig, ax = plt.subplots(figsize=(12, 4.5))

sns.heatmap(
    datos_heatmap_recomendacion,
    annot=True,
    fmt='.1f',
    cmap='YlOrRd',
    linewidths=0.5,
    cbar_kws={'label': '% de reseñas del segmento'},
    ax=ax,
)

ax.set(
    title='Categorías negativas de RE/MAX según la recomendación',
    xlabel='Categoría mencionada en cons',
    ylabel='¿Recomendaría RE/MAX?',
)
plt.xticks(rotation=25, ha='right')
plt.tight_layout()

fig.savefig(
    IMAGES_DIR / 'segmentacion_cons_por_recomendacion_remax.png',
    dpi=160,
    bbox_inches='tight',
)

plt.show()
```



Lectura por recomendación

La segmentación confirma dos comportamientos diferentes. `Compensación, comisiones y costes` tiene un peso elevado en los tres grupos: aparece en el 23,46% de quienes recomiendan RE/MAX, el 30,02% de las respuestas neutrales y el 29,63% de quienes no la recomiendan. Se trata, por tanto, de una fricción transversal y no exclusiva de los detractores.

`Cultura, liderazgo y equipo` es la categoría que más distingue a quienes no recomendarían la empresa: representa el 21,48% de sus cons, frente al 4,98% entre quienes sí la recomiendan y el 4,29% entre las respuestas neutrales. Este resultado confirma que la cultura no es una debilidad generalizada, pero cuando falla tiene una asociación muy fuerte con la pérdida de recomendación.

El rating medio pasa de 4,59 entre quienes recomiendan RE/MAX a 2,47 entre quienes no lo hacen. La relación es coherente con el resto del análisis, pero sigue siendo descriptiva: rating, recomendación y comentario proceden de la misma reseña y no permiten identificar una causa individual.

---

6. Áreas de mejora y matriz de priorización

La priorización combina dos dimensiones:

- El peso de cada categoría en los cons de RE/MAX.
- La desventaja del balance neto de RE/MAX frente a los peers.

Una categoría es prioritaria cuando tiene una presencia material en los cons y, al mismo tiempo, RE/MAX presenta un balance peor que la competencia. Como referencia operativa, se considera material un peso mínimo del 5%, equivalente aproximadamente a 50 reseñas en la muestra de RE/MAX.

In [52]:
```
# Preparación de la matriz de priorización para la toma de decisiones

matriz_priorizacion = (
    comparacion_negocio[
        [
            'Cons RE/MAX (%)',
            'Gap balance vs. peers',
        ]
    ]
    .rename(columns={
        'Cons RE/MAX (%)': 'Peso en cons RE/MAX (%)',
    })
    .copy()
)

# El gap se invierte para que un valor positivo represente desventaja.
matriz_priorizacion['Desventaja vs. peers'] = (
    -matriz_priorizacion['Gap balance vs. peers']
)

matriz_priorizacion = matriz_priorizacion.join(
    validacion_categorias[
        [
            'n_reseñas',
            'gap_rating_vs_total_remax',
            'gap_recomendacion_vs_total_remax',
        ]
    ],
    how='left',
)

matriz_priorizacion = matriz_priorizacion.sort_values(
```

```
    ['Desventaja vs. peers', 'Peso en cons RE/MAX (%)'],
    ascending=False,
)

matriz_priorizacion.round(2)
```

Out[52]:

	Peso en cons RE/MAX (%)	Gap balance vs. peers	Desventaja vs. peers	n_reseñas	gap_rating_vs_total_remax	gap_recomendacion_vs_total_remax
Compensación, comisiones y costes	27.2	-9.35	9.35	272.0	-0.21	-5.80
Modelo de negocio y mercado	5.0	-1.63	1.63	50.0	0.00	7.80
Oficinas y entorno físico	2.1	-1.34	1.34	21.0	0.05	5.42
Formación, onboarding y soporte	6.1	-0.59	0.59	61.0	0.10	-4.50
Carrera y desarrollo	2.4	-0.19	0.19	24.0	-0.30	3.63
Estructura y organización	1.3	0.88	-0.88	13.0	0.21	19.34
Tecnología, herramientas y procesos	1.6	1.07	-1.07	16.0	-0.16	-4.70
Ventas, clientes y captación	3.3	1.37	-1.37	33.0	-0.28	0.22
Flexibilidad, conciliación y carga de trabajo	10.8	2.22	-2.22	108.0	0.21	5.02
Cultura, liderazgo y equipo	6.9	2.46	-2.46	69.0	-0.89	-11.77
Marca y reputación	0.0	8.69	-8.69	NaN	NaN	NaN

In [53]:

```
# Clasificación de las señales
def clasificar_prioridad(fila):
    peso_material = fila['Peso en cons RE/MAX (%)'] >= 5
    peor_que_peers = fila['Desventaja vs. peers'] > 0
    peor_rating = fila['gap_rating_vs_total_remax'] < 0
    menor_recomendacion = (
        fila['gap_recomendacion_vs_total_remax'] < 0
    )

    if (
        peso_material
        and peor_que_peers
        and peor_rating
        and menor_recomendacion
    ):
        return 'Prioridad alta'
```

```
    if peso_material and peor_que_peers:
        return 'Revisar'

    if (
        not peor_que_peers
        and (peor_rating or menor_recomendacion)
    ):
        return 'Problema interno, no diferencial'

    return 'No prioritaria'


matriz_priorizacion['Clasificación'] = (
    matriz_priorizacion.apply(
        clasificar_prioridad,
        axis=1,
    )
)

matriz_priorizacion.round(2)
```

Out[53]:

	Peso en cons RE/MAX (%)	Gap balance vs. peers	Desventaja vs. peers	n_reseñas	gap_rating_vs_total_remax	gap_recomendacion_vs_total_remax	Clasificación
Compensación, comisiones y costes	27.2	-9.35	9.35	272.0	-0.21	-5.80	Prioridad alta
Modelo de negocio y mercado	5.0	-1.63	1.63	50.0	0.00	7.80	Revisar
Oficinas y entorno físico	2.1	-1.34	1.34	21.0	0.05	5.42	No prioritaria
Formación, onboarding y soporte	6.1	-0.59	0.59	61.0	0.10	-4.50	Revisar
Carrera y desarrollo	2.4	-0.19	0.19	24.0	-0.30	3.63	No prioritaria
Estructura y organización	1.3	0.88	-0.88	13.0	0.21	19.34	No prioritaria
Tecnología, herramientas y procesos	1.6	1.07	-1.07	16.0	-0.16	-4.70	Problema interno, no diferencial
Ventas, clientes y captación	3.3	1.37	-1.37	33.0	-0.28	0.22	Problema interno, no diferencial
Flexibilidad, conciliación y carga de trabajo	10.8	2.22	-2.22	108.0	0.21	5.02	No prioritaria
Cultura, liderazgo y equipo	6.9	2.46	-2.46	69.0	-0.89	-11.77	Problema interno, no diferencial
Marca y reputación	0.0	8.69	-8.69	NaN	NaN	NaN	No prioritaria

Lectura de la matriz

La matriz utiliza dos ejes:

- **Eje horizontal:** porcentaje de reseñas negativas de RE/MAX asociado a cada categoría. Se considera que una categoría tiene un peso material cuando alcanza al menos el 5 %.
- **Eje vertical:** desventaja del balance de RE/MAX frente a sus peers. Los valores positivos indican que RE/MAX presenta un resultado peor que la competencia; los negativos indican una posición relativa más favorable.

Los cuatro cuadrantes se interpretan de la siguiente manera:

1. **Prioridad competitiva:** categoría frecuente en RE/MAX y con peor balance que los peers.

2. **Señal emergente:** peor balance que los peers, pero todavía con una frecuencia reducida.
3. **Problema interno o compartido:** categoría frecuente, pero en la que RE/MAX no presenta una desventaja frente a los peers.
4. **Baja prioridad o fortaleza relativa:** categoría poco frecuente y sin desventaja competitiva.

El color de fondo identifica el cuadrante. El color de cada burbuja muestra la clasificación final después de incorporar también su impacto sobre el rating y la recomendación. El tamaño de la burbuja representa el número de reseñas de RE/MAX asociadas a la categoría.

In [54]:
```python
# Visualización de la matriz de priorización

from matplotlib.lines import Line2D
from matplotlib.patches import Rectangle

ETIQUETAS_CORTAS = {
    CULTURA: 'Cultura y liderazgo',
    FLEXIBILIDAD: 'Flexibilidad',
    COMPENSACION: 'Compensación',
    FORMACION: 'Formación',
    CARRERA: 'Carrera',
    MARCA: 'Marca',
    VENTAS: 'Ventas y clientes',
    TECNOLOGIA: 'Tecnología',
    OFICINAS: 'Oficinas',
    MODELO_NEGOCIO: 'Modelo de negocio',
    ESTRUCTURA: 'Estructura',
}

# El color de la burbuja recoge la clasificación final,
# después de considerar frecuencia, peers, rating y recomendación.
COLORES_PRIORIDAD = {
    'Prioridad alta': '#C1121F',
    'Revisar': '#F28E2B',
    'Problema interno, no diferencial': '#D4A017',
    'No prioritaria': '#168AAD',
}

# Colores suaves para los cuatro cuadrantes.
COLORES_CUADRANTES = {
    'prioridad_competitiva': '#FADBD8',
    'señal_emergente': '#FDEBD0',
    'problema_interno': '#FCF3CF',
    'baja_prioridad': '#D5F5E3',
}

UMBRAL_PESO = 5
UMBRAL_DESVENTAJA = 0
```

```python
# Límites dinámicos para que las etiquetas no queden pegadas a los bordes.
x_min = 0
x_max = max(
    30,
    matriz_priorizacion['Peso en cons RE/MAX (%)'].max() * 1.20,
)

y_min = min(
    -10,
    matriz_priorizacion['Desventaja vs. peers'].min() * 1.20,
)

y_max = max(
    10,
    matriz_priorizacion['Desventaja vs. peers'].max() * 1.20,
)

fig, ax = plt.subplots(figsize=(13, 8))

# ------------------------------------------------------------------
# Fondos de los cuatro cuadrantes
# ------------------------------------------------------------------

# Superior izquierdo: poco frecuente, pero peor que los peers.
ax.add_patch(
    Rectangle(
        (x_min, UMBRAL_DESVENTAJA),
        UMBRAL_PESO - x_min,
        y_max - UMBRAL_DESVENTAJA,
        facecolor=COLORES_CUADRANTES['señal_emergente'],
        alpha=0.55,
        zorder=0,
    )
)

# Superior derecho: frecuente y peor que los peers.
ax.add_patch(
    Rectangle(
        (UMBRAL_PESO, UMBRAL_DESVENTAJA),
        x_max - UMBRAL_PESO,
        y_max - UMBRAL_DESVENTAJA,
        facecolor=COLORES_CUADRANTES['prioridad_competitiva'],
        alpha=0.55,
        zorder=0,
    )
)

# Inferior izquierdo: poco frecuente y sin desventaja competitiva.
ax.add_patch(
    Rectangle(
```

```
        (x_min, y_min),
        UMBRAL_PESO - x_min,
        UMBRAL_DESVENTAJA - y_min,
        facecolor=COLORES_CUADRANTES['baja_prioridad'],
        alpha=0.55,
        zorder=0,
    )
)

# Inferior derecho: frecuente, pero no peor que los peers.
ax.add_patch(
    Rectangle(
        (UMBRAL_PESO, y_min),
        x_max - UMBRAL_PESO,
        UMBRAL_DESVENTAJA - y_min,
        facecolor=COLORES_CUADRANTES['problema_interno'],
        alpha=0.55,
        zorder=0,
    )
)

# ----------------------------------------------------------------------
# Títulos de los cuadrantes
# ----------------------------------------------------------------------

estilo_cuadrante = {
    'fontsize': 9,
    'fontweight': 'bold',
    'color': '#333333',
    'bbox': {
        'boxstyle': 'round,pad=0.35',
        'facecolor': 'white',
        'edgecolor': 'none',
        'alpha': 0.75,
    },
}

ax.text(
    UMBRAL_PESO / 2,
    y_max - 0.7,
    'SEÑAL\nEMERGENTE',
    ha='center',
    va='top',
    **estilo_cuadrante,
)

ax.text(
    UMBRAL_PESO + 0.7,
    y_max - 0.7,
    'PRIORIDAD COMPETITIVA',
```

```
    ha='left',
    va='top',
    **estilo_cuadrante,
)

ax.text(
    UMBRAL_PESO / 2,
    y_min / 2,
    'BAJA\nPRIORIDAD',
    ha='center',
    va='center',
    **estilo_cuadrante,
)

ax.text(
    UMBRAL_PESO + 0.7,
    y_min + 0.7,
    'PROBLEMA INTERNO\nO COMPARTIDO',
    ha='left',
    va='bottom',
    **estilo_cuadrante,
)

# ------------------------------------------------------------------
# Burbujas de las categorías
# ------------------------------------------------------------------

for categoria, fila in matriz_priorizacion.iterrows():
    clasificacion = fila['Clasificación']

    n_reseñas = fila['n_reseñas']
    tamaño = (
        70
        if pd.isna(n_reseñas)
        else max(70, n_reseñas * 2)
    )

    ax.scatter(
        fila['Peso en cons RE/MAX (%)'],
        fila['Desventaja vs. peers'],
        s=tamaño,
        color=COLORES_PRIORIDAD[clasificacion],
        alpha=0.90,
        edgecolor='white',
        linewidth=1.2,
        zorder=3,
    )

    ax.annotate(
        ETIQUETAS_CORTAS[categoria],
```

```
            (
                fila['Peso en cons RE/MAX (%)'],
                fila['Desventaja vs. peers'],
            ),
            xytext=(7, 6),
            textcoords='offset points',
            fontsize=9,
            zorder=4,
        )

# Líneas divisorias.
ax.axvline(
    UMBRAL_PESO,
    color='#555555',
    linestyle='--',
    linewidth=1.3,
    zorder=2,
)

ax.axhline(
    UMBRAL_DESVENTAJA,
    color='#333333',
    linewidth=1.3,
    zorder=2,
)

ax.set_xlim(x_min, x_max)
ax.set_ylim(y_min, y_max)

ax.set(
    title='Matriz de priorización de áreas de mejora en RE/MAX',
    xlabel='Peso de la categoría en los cons de RE/MAX (%)',
    ylabel='Desventaja del balance frente a los peers (puntos porcentuales)',
)

ax.grid(alpha=0.18, zorder=1)

# ------------------------------------------------------------------
# Leyenda del color de las burbujas
# ------------------------------------------------------------------

elementos_leyenda = [
    Line2D(
        [0],
        [0],
        marker='o',
        linestyle='',
        markersize=9,
        markerfacecolor=color,
        markeredgecolor='white',
```

```
        label=clasificacion,
    )
    for clasificacion, color in COLORES_PRIORIDAD.items()
]

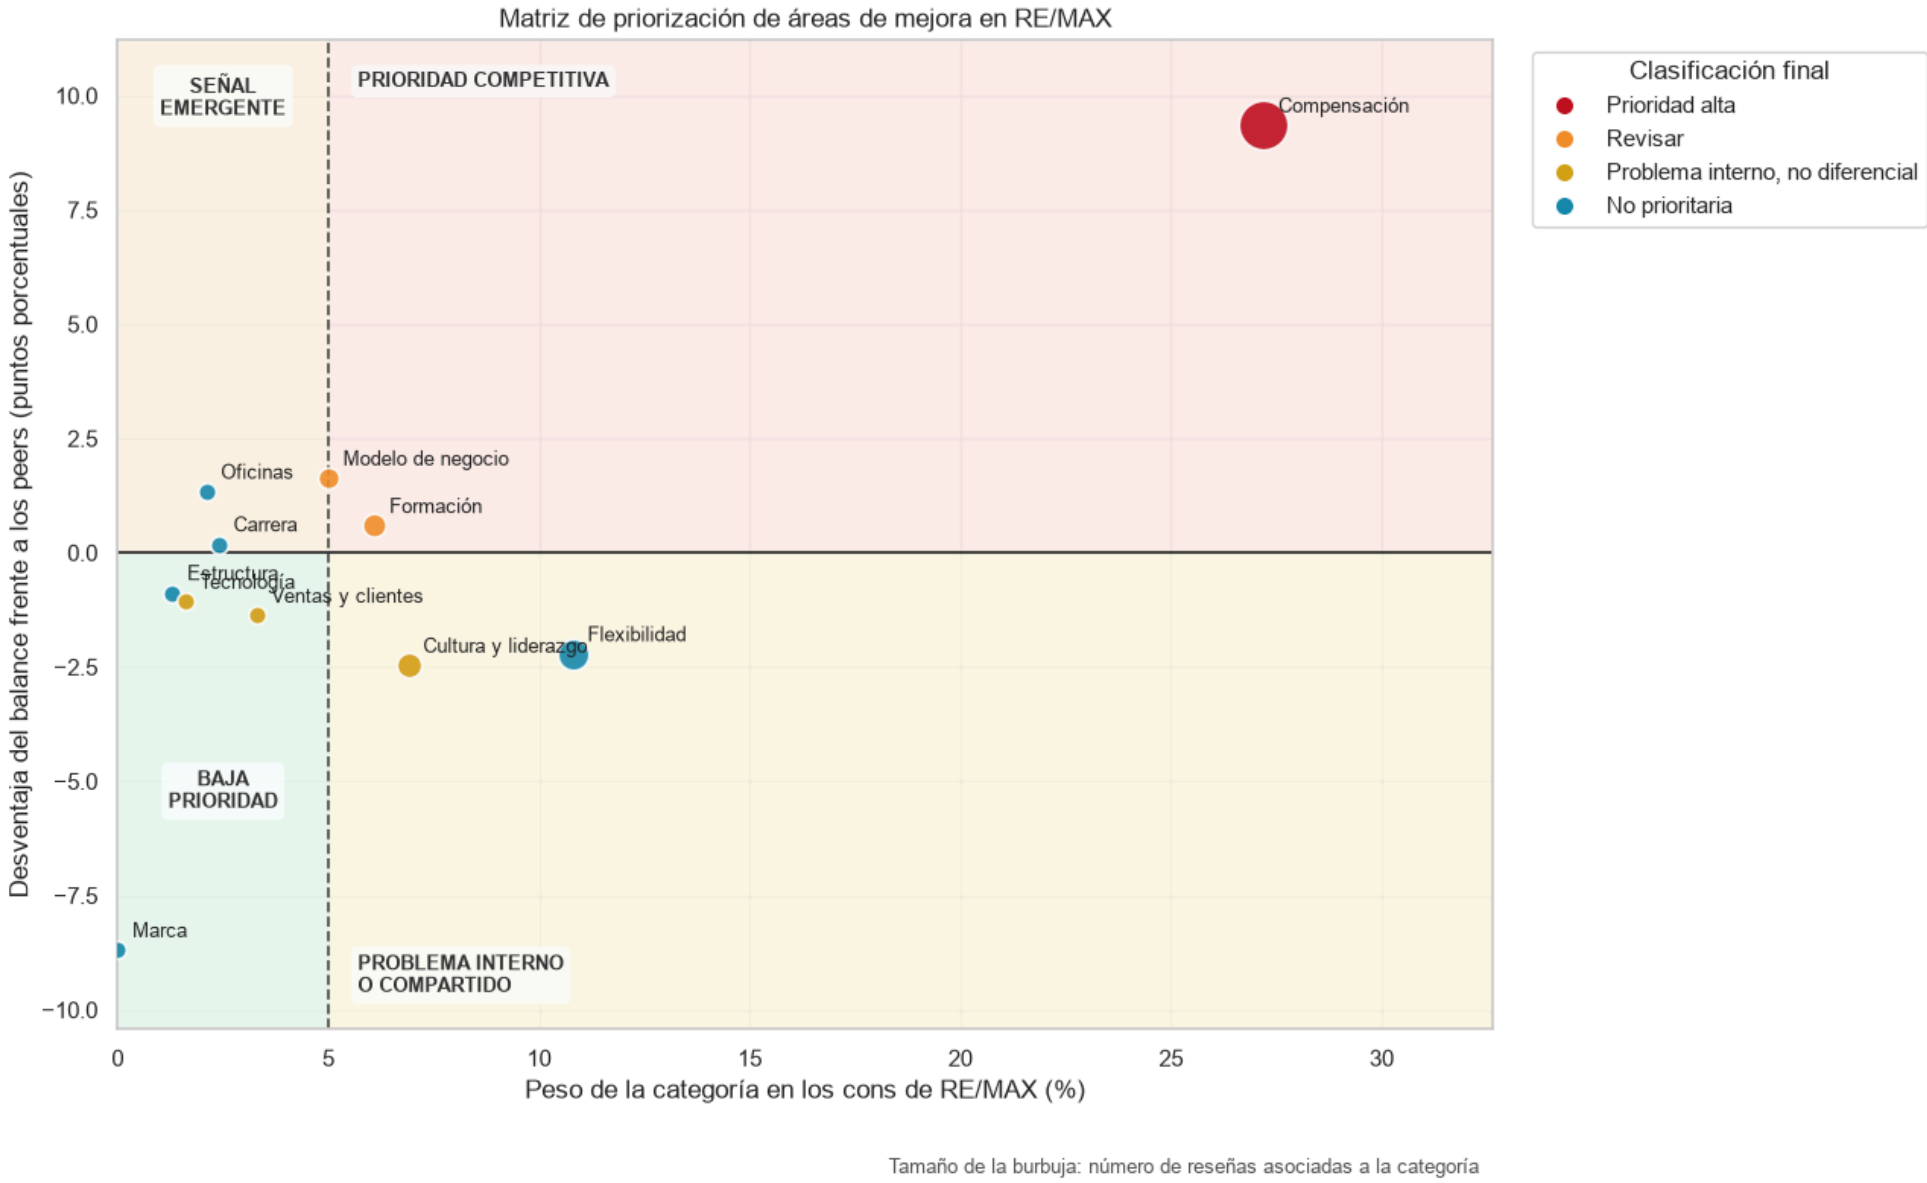
ax.legend(
    handles=elementos_leyenda,
    title='Clasificación final',
    loc='upper left',
    bbox_to_anchor=(1.02, 1),
    frameon=True,
)

ax.text(
    0.99,
    -0.13,
    'Tamaño de la burbuja: número de reseñas asociadas a la categoría',
    transform=ax.transAxes,
    ha='right',
    va='top',
    fontsize=9,
    color='#555555',
)

plt.tight_layout()

fig.savefig(
    IMAGES_DIR / 'matriz_priorizacion_remax.png',
    dpi=160,
    bbox_inches='tight',
)

plt.show()
```



In [55]:
```
matriz_priorizacion.to_csv(
    OUTPUTS_DIR / 'matriz_priorizacion_remax.csv',
)

print(
```

```
    OUTPUTS_DIR /
    'matriz_priorizacion_remax.csv'
)
```

../outputs/matriz_priorizacion_remax.csv

Interpretación de la matriz de priorización

La matriz combina la frecuencia de cada área en las reseñas negativas de RE/MAX, su diferencia respecto a los peers y su impacto sobre el rating y la recomendación de la empresa.

Los resultados muestran que **compensación, comisiones y costes constituye la principal prioridad de actuación**. Esta categoría representa el 27,2 % de los comentarios negativos de RE/MAX, aparece 9,35 puntos porcentuales más que entre sus competidores y está asociada con un rating 0,21 puntos inferior y una recomendación 5,8 puntos porcentuales menor que la media de la compañía. La convergencia de estos indicadores permite considerarla una debilidad competitiva y no únicamente un problema interno.

El **modelo de negocio y las condiciones de mercado** y la **formación y el acompañamiento inicial** quedan clasificados como áreas que conviene revisar, aunque con menor prioridad. En ambos casos, la desventaja respecto a los peers es reducida y los indicadores de satisfacción no muestran un deterioro generalizado. Por ello, sería conveniente profundizar en estas cuestiones antes de plantear cambios estructurales.

La **cultura y el liderazgo** presentan una situación diferente. RE/MAX recibe proporcionalmente menos críticas sobre esta materia que sus competidores, por lo que constituye una fortaleza relativa. Sin embargo, cuando aparece en una reseña negativa, se asocia con una caída de 0,89 puntos en el rating y de 11,8 puntos porcentuales en la recomendación. Por tanto, no parece un problema generalizado de la organización, pero sí un posible foco de riesgo localizado en determinadas oficinas, equipos o responsables.

Finalmente, la **marca** y la **flexibilidad** aparecen como fortalezas diferenciales. Estas dimensiones pueden aprovecharse en la propuesta de valor al empleado y al asociado, siempre que se comuniquen de forma realista junto con las condiciones económicas y las exigencias propias del modelo de trabajo.

---

7. Recomendaciones para Recursos Humanos

A partir del análisis exploratorio, de sentimiento, temático y de la matriz de priorización, se proponen tres líneas de actuación.

1. Mejorar la transparencia sobre comisiones, costes e ingresos esperados

RE/MAX debería facilitar, antes de la incorporación, una explicación homogénea y comprensible de las comisiones, cuotas, gastos de oficina, costes comerciales y otros conceptos que afectan al ingreso neto del asociado.

Como medidas concretas se propone:

- Crear un simulador de ingresos netos con distintos escenarios de facturación.
- Entregar un documento normalizado con todos los costes asociados a la actividad.
- Revisar las condiciones y dificultades específicas del primer año.
- Analizar las diferencias entre oficinas para detectar estructuras especialmente desfavorables.
- Incorporar entrevistas de salida que permitan distinguir entre problemas de rentabilidad, falta de ventas y desacuerdo con las condiciones económicas.

Los indicadores de seguimiento podrían ser la rotación durante los primeros 6 y 12 meses, el porcentaje de asociados que declara comprender el modelo económico y el número de salidas relacionadas con comisiones o costes.

2. Detectar focos localizados de cultura o liderazgo

La cultura no constituye una desventaja general frente a los peers, pero las reseñas que mencionan problemas culturales o de liderazgo presentan un impacto muy elevado sobre la valoración y la recomendación.

Debido al carácter descentralizado y basado en oficinas o franquicias del modelo de RE/MAX, no debería interpretarse automáticamente como un problema uniforme de toda la organización. Se recomienda:

- Realizar encuestas breves y periódicas segmentadas por oficina y responsable.
- Establecer canales confidenciales para comunicar problemas de liderazgo.
- Comparar rotación, satisfacción y recomendación entre oficinas.
- Ofrecer formación en liderazgo, comunicación y gestión de conflictos a brokers y responsables.
- Intervenir prioritariamente en las oficinas que acumulen resultados negativos.

El objetivo sería detectar problemas concretos antes de que se conviertan en una percepción general de la marca empleadora.

3. Reforzar una propuesta de valor realista y un onboarding estructurado

La marca y la flexibilidad son fortalezas diferenciales de RE/MAX y pueden utilizarse para atraer y fidelizar talento. No obstante, deben presentarse junto con información realista sobre la autonomía, la necesidad de generar negocio, los costes de la actividad y la variabilidad de los

ingresos.

Se propone desarrollar un programa de incorporación de 90 días que combine:

- Formación comercial y operativa.
- Mentorización durante los primeros meses.
- Explicación práctica del modelo económico.
- Objetivos progresivos y realistas.
- Seguimiento de la adaptación del nuevo asociado.
- Comunicación de las ventajas de la marca, la red y la flexibilidad.

Esta actuación permitiría aprovechar las fortalezas identificadas y, al mismo tiempo, reducir posibles diferencias entre las expectativas iniciales y la experiencia real.

In [56]:
```
# Resumen ejecutivo de recomendaciones para RRHH
recomendaciones_rrhh = pd.DataFrame([
    {
        'prioridad': 1,
        'area': 'Compensación, comisiones y costes',
        'diagnostico': (
            'Principal debilidad competitiva: elevada frecuencia y efecto '
            'negativo sobre rating y recomendación.'
        ),
        'accion_principal': (
            'Estandarizar la información económica, crear un simulador de '
            'ingresos netos y revisar las condiciones del primer año.'
        ),
        'indicadores': (
            'Rotación a 6/12 meses; comprensión del modelo económico; '
            'salidas relacionadas con costes o comisiones.'
        )
    },
    {
        'prioridad': 2,
        'area': 'Cultura y liderazgo',
        'diagnostico': (
            'Fortaleza relativa frente a los peers, pero con impacto muy '
            'negativo cuando el problema aparece.'
        ),
        'accion_principal': (
            'Detectar oficinas o responsables con resultados anómalos mediante '
            'encuestas, canales confidenciales y análisis segmentado.'
        ),
        'indicadores': (
```

```
            'Satisfacción y recomendación por oficina; rotación; incidencias '
            'y tiempo de resolución.'
        )
    },
    {
        'prioridad': 3,
        'area': 'Propuesta de valor y onboarding',
        'diagnostico': (
            'Marca y flexibilidad como fortalezas, con necesidad de ajustar '
            'expectativas sobre costes, autonomía y generación de negocio.'
        ),
        'accion_principal': (
            'Implantar un onboarding de 90 días con formación, mentoría, '
            'seguimiento y explicación del modelo económico.'
        ),
        'indicadores': (
            'Finalización de la formación; adaptación inicial; tiempo hasta '
            'la primera operación; rotación temprana.'
        )
    }
])

display(recomendaciones_rrhh)
```

	prioridad	area	diagnostico	accion_principal	indicadores
0	1	Compensación, comisiones y costes	Principal debilidad competitiva: elevada frecu...	Estandarizar la información económica, crear u...	Rotación a 6/12 meses; comprensión del modelo ...
1	2	Cultura y liderazgo	Fortaleza relativa frente a los peers, pero co...	Detectar oficinas o responsables con resultado...	Satisfacción y recomendación por oficina; rota...
2	3	Propuesta de valor y onboarding	Marca y flexibilidad como fortalezas, con nece...	Implantar un onboarding de 90 días con formaci...	Finalización de la formación; adaptación inici...

In [57]:

```
ruta_recomendaciones = OUTPUTS_DIR / 'recomendaciones_rrhh_remax.csv'

recomendaciones_rrhh.to_csv(
    ruta_recomendaciones,
    index=False,
    encoding='utf-8-sig'
)

print(f'Recomendaciones guardadas en: {ruta_recomendaciones.resolve()}')
```

```
Recomendaciones guardadas en:
/Users/jobdelgadoiniesta/Documents/EVOLVE/06_DeepLearning/proyecto_modular_deeplearning/outputs/recomendaciones_rrhh_remax.csv
```

8. Limitaciones del análisis

Los resultados deben interpretarse teniendo en cuenta las siguientes limitaciones:

- Las reseñas de Glassdoor son voluntarias y pueden no representar a toda la plantilla o red de asociados.
- Los datos agrupan oficinas, países, funciones y modalidades laborales diferentes.
- En una red de franquicias, una experiencia negativa puede depender de una oficina o responsable concreto y no de toda la organización.
- La condición de empleado actual o antiguo no permite conocer el momento exacto de la salida ni demostrar qué la provocó.
- La diferencia entre empleados actuales y antiguos puede reflejar tanto la experiencia posterior de quienes salieron como la evolución de la propia empresa.
- Las comparaciones temporales utilizan la fecha de publicación de la reseña, que no necesariamente coincide con el periodo en el que se produjo la experiencia descrita.
- La muestra fue limitada a un máximo de 1.000 reseñas por empresa, mientras que algunas compañías disponían de menos observaciones.
- Los modelos de sentimiento y tópicos pueden cometer errores, especialmente ante negaciones, ironía, textos ambiguos o comentarios que contienen varias ideas.
- La agrupación de tópicos en categorías de negocio incorpora una interpretación manual.
- El análisis identifica asociaciones, pero no permite establecer relaciones causales ni afirmar que una categoría concreta sea por sí sola el motivo de abandono.

9. Conclusión

RE/MAX presenta una valoración global favorable y superior a la media de los peers analizados. La marca, la flexibilidad y determinados aspectos culturales constituyen ventajas relevantes que pueden reforzar su posicionamiento como empleador y como red para profesionales inmobiliarios.

La principal debilidad identificada se concentra en la compensación, las comisiones y los costes asociados al modelo de trabajo. Se trata del área con mayor frecuencia entre los comentarios negativos, la mayor desventaja frente a los competidores y un efecto desfavorable sobre el rating y la recomendación.

La cultura y el liderazgo no aparecen como una debilidad competitiva general, pero sí como un riesgo de elevada intensidad cuando se producen experiencias negativas. Esto aconseja realizar un seguimiento segmentado por oficina, equipo y responsable.

La menor valoración de los antiguos empleados puede responder a diferentes mecanismos: experiencias negativas previas a la salida, ampliación de sus referencias al conocer otros modelos de trabajo o exposición a procesos organizativos anteriores. Con los datos disponibles no es posible separar estos efectos ni atribuirles causalidad.

Los análisis complementarios refuerzan esta priorización. Las críticas económicas se mantienen por encima de los peers durante toda la serie temporal y aumentan en varios tramos de mayor antigüedad. En cambio, las menciones a formación y onboarding descienden con el tiempo, lo que apunta a una posible mejora de los procesos. La cultura aparece con poca frecuencia en el conjunto, pero alcanza el 21,48% de los cons entre quienes no recomendarían RE/MAX, confirmando su carácter de riesgo localizado y de elevada intensidad.

En consecuencia, la estrategia de Recursos Humanos debería combinar una mayor transparencia económica, la detección temprana de focos locales de liderazgo y un proceso de incorporación que comunique de forma equilibrada tanto las ventajas como las exigencias del modelo RE/MAX.